The Andrew and Erna Viterbi Faculty of ELECTRICAL & COMPUTER ENGINEERING

SIPL

TECHNION Israel Institute of Technology

דו"ח סיכום פרויקט: א'

תקיפות ערוצי צד במערכות קריפטוגרפיות

Side-Channel Analysis for Cryptographic Systems

מבצע:

תום סוסטיאל **Tom Soustiel**

מנחה:

נורית ספינגרן **Nurit Spingran**

מנחה מטעם התעשיה:

דוקטור מ. אביטל **Doctor M. Avital**

סמסטר רישום: חורף תשפ"ו

תאריך הגשה:

בשיתוף עם: רפאל מערכות לחימה מתקדמות

RAFAEL ADVANCED DEFENSE SYSTEMS LTD.

P 10622 -1-26

תודות

אני מודה למנחה מטעם מעבדת SIPL – נורית ספינגרן, על הנחיה והכוונה בתחום למידה עמוקה לכל אורך הפרויקט. תודה על הסבלנות והרעיונות שעזרו לקדם את המטרה.

אני מודה למנחה מטעם רפאל – דוקטור משה אביטל, על הנחייה והכוונה בתחום ערוצי צד המהווה את הבסיס לפרויקט. תודה על שיתוף הידע הרב ודחיפת הפרויקט קדימה.

אני מודה למעבדת SIPL ובפרט לרועי מיתרני על מתן המשאבים הנחוצים לפרויקט והתמיכה לכל אורכו, על העזרה עוד לפני שנתבקשה.

אני מודה לחברת רפאל על ההזדמנות לשיתוף פעולה פורה, ומתן האפשרות לביצוע פרויקט מרתק.

תוכן עניינים

1. מטרת הפרויקט v
2. סקר ספרות..... 1
3. רקע תיאורטי 2
3.1. תקן הצפנת AES..... 2
3.2. נקודות התורפה לדליפת מידע בהצפנת AES 2
3.3. מקורות דליפה במיקרו מעבדים והשפעת מנגנון המיסוך 2
4. הפתרון הנבחר 3
4.1. ניתוח יחס אות לרעש ומאפייני מערך הנתונים ASCAD_r 3
4.2. מודל ראשוני 4
4.1.1. מודל Multi-Task מבוסס ResNet 5
4.1.2. המעבר לגישת ה"קופסה השחורה" 6
4.2. שלבי פיתוח מודל סופי 7
4.3. המודל הנבחר 7
5. תוצאות 11
5.1. תוצאות ביניים: ResNet VS CNN 11
5.2. ניסיון מימוש Black Box 12
5.3. הארכיטקטורה הנבחרת..... 13
5.3.1. ניתוח למידת המודל הנבחר 13
5.3.2. ניתוח תקיפת המודל הנבחר..... 14
6. סיכום ומסקנות 16
6.1. סיכום 16
6.2. תובנות 16
7. כיווני מחקר עתידיים..... 17
9. נספחים..... 19

רשימת איורים

איור 1 – מודל לתקיפת מיסוך בוליאני 5
איור 2 – מודל גנרי ראשוני..... 6
איור 3 - הפתרון הנבחר..... 8
איור 4 – Training & Validation Loss VS Epoch עבור מודל הבסיס מתוך המאמר עם שלד CNN.... 11
איור 5 – Training & Validation Loss VS Epoch עבור מודל הבסיס מתוך המאמר עם שלד ResNet 11
איור 6 – Training & Validation Loss VS Epoch עם שכבה בילינארית עם קלט Softmax..... 12
איור 7 – Training & Validation Loss VS Epoch מודל ראשוני ללא שכבות XOR 12
איור 8 – Training & Validation Loss VS Epoch עם שכבה בילינארית עם קלט Logits..... 13
איור 9 Guessing Entropy VS #Traces, המודל הנבחר כנגד מודל הבסיס..... 15
איור 10 - יחס אות לרעש מסדר ראשון על פני מצפין לא ממוסך..... 19
איור 11 – יחס אות לרעש מסדר ראשון ASCAD_r..... 20
איור 12 – יחס אות לרעש מסדר שני ASCAD_r 21
איור 13 – ביצועי המודל הנבחר על פני עקבה בודדת: אחוז העקבות מתוך 10K עקבות עבורן דורג כל בית
במקומות הראשונים בתקיפה..... 22
איור 14 – ביצועי המודל הנבחר על פני מספר עקבות: מספר העקבות המינימלי לחילוץ מלא של המפתח
הסודי..... 23
איור15 - ביצועי מודל הבסיס על פני עקבה בודדת: אחוז העקבות מתוך 10K עקבות עבורן דורג כל בית
במקומות הראשונים בתקיפה..... 24
איור 16 – ביצועי מודל הבסיס על פני מספר עקבות: מספר העקבות המינימלי לחילוץ מלא של המפתח
הסודי..... 25

תקציר

מערכות קריפטוגרפיות, אף שהן חסינות מבחינה מתמטית, נותרות פגיעות להתקפות ניתוח ערוצי צד (SCA) המנצלות דליפות מידע פיזיות כגון צריכת הספק ופליטות אלקטרומגנטיות. שיטות SCA נוכחיות המבוססות על למידה עמוקה הן לרוב בלתי מעשיות, שכן הן מסתמכות על ידע ספציפי של אופן מימוש ההצפנה או דורשות נתונים מתויגים של מנגנוני המיסוך (masking) הפנימיים, אליהם בדרך כלל אין גישה בצורה בלתי פולשנית. פרויקט זה מציג ארכיטקטורת Black-Box של למידה עמוקה, המסוגלת לחלץ מפתחות סודיים של הצפנת AES ממוסכת ללא ידע מוקדם על מימוש המיסוך. הגישה שלנו משתמשת בתשתית של למידה מרובת-משימות (MTL) עם שלד ResNet עמוק כדי לעבד את העקבות (traces) הגולמיים ולחזות את כל בתי המפתח בו-זמנית. כדי להתגבר על התלות ברכיבים קשיחים ייעודיים למיסוך ספציפי, אנו מציגים שכבת Bilinear-Combiner נלמדת המבוססת על פירוק Canonical Polyadic (CP) , המאפשרת למודל לגלות באופן טבעי את פעולות הסרת המיסוך ישירות מהנתונים. על ידי שילוב של חיבורי דילוג (skip connections) , רגולריזציית L2 והזרקת רעש גאוסי, אנו מצליחים למזער את תופעת Vanishing Gradient ולמנוע התאמת יתר. תוצאות ניסיוניות מוכיחות כי המודל האגנוסטי-למיסוך שלנו משיג ביצועים טובים, ומשחזר בהצלחה את כל בתי המפתח הסודי של AES עם אנטרופיית ניחוש מושלמת (Guessing Entropy) תוך שימוש ב-2 עד 4 עקבות בלבד על מערך הנתונים עם מיסוך בוליאני ASCAD_r (גרסה מצומצמת של מאגר ASCAD_v1), זאת לעומת 3-14 עקבות הנדרשות עבור מודל הבסיס עליו אנו מסתמכים בפרויקט זה, מה שמקדם משמעותית את הישימות של התקפות SCA בעולם האמיתי.

ניתן לשחזר את השימוש במודל ואת התוצאות המתוארות בפרויקט זה בקישור BlackBox DLSCA.

Abstract

Cryptographic systems, while mathematically secure, remain vulnerable to Side-Channel Analysis (SCA) attacks that exploit physical leakages such as power consumption and electromagnetic emissions. Existing deep learning–based SCA approaches are often impractical in real-world attack scenarios, as they rely on implementation-specific knowledge or require labeled internal masking data that is typically unavailable to a non-invasive attacker. This project presents a masking-agnostic, black-box deep learning architecture capable of recovering secret keys from masked AES implementations without any prior knowledge of the masking scheme or access to internal intermediate values. Our approach utilizes a Multi-Task Learning (MTL) framework with a deep ResNet backbone to process raw traces and predict all key bytes simultaneously. To eliminate the dependency on hard-coded, mask-specific operations, we introduce a learnable bilinear combiner layer based on Canonical Polyadic (CP) decomposition. This layer enables the model to naturally learn the demasking operation directly from data, without explicit supervision. By integrating residual connections, L2 regularization, and Gaussian noise injection, the architecture ensures stable gradient flow and mitigates overfitting. Experimental results demonstrate that our masking-agnostic model achieves superior performance, successfully recovering all AES secret key bytes with perfect Guessing Entropy using as few as 2-4 traces on the ASCAD_r dataset with Boolean masking, significantly advancing the practicality of real-world SCA attacks. These results significantly advance the practical applicability of deep learning–based SCA in realistic black-box attack settings.

To replicate the results, the following repository is provided BlackBox DLSCA.

1. מטרת הפרויקט

מערכות קריפטוגרפיות, אף שהן חסינות מתמטית, חשופות לדליפת מידע באמצעות ערוצי צד. קיימים כיום כלים, בעיקר סטטיסטיים, המאפשרים לחלץ מידע רגיש ממערכות אלו. מטרת הפרויקט היא הטמעת כלי בינה מלאכותית לטובת תקיפת ערוצי צד, ובכך להרחיב את מנעד היכולות של תקיפות אלו ואת מגוון אמצעי הנגד הנדרשים להתמודדות עימן.

בנוסף לכך, יעד מרכזי שהוגדר במהלך הפרויקט, הוא פיתוח מודל תקיפה מבוסס למידה עמוקה הפועל כ"קופסה שחורה" – Black Box. המשמעות היא יצירת מודל המסוגל לחלץ את מפתח ההצפנה הסודי ללא כל ידע מוקדם על אופן המימוש, וחשוב מכך, ללא הסתמכות על נתוני ביניים פנימיים של הצפנת AES, כגון נתוני מיסוך פנימיים או תוויות ביניים.

2. סקר ספרות

סקר הספרות בתחום ניתוח ערוצי צד (SCA) מצביע על מעבר משמעותי משיטות למידת מכונה מסורתיות (כגון SVM ו-Random Forests) לארכיטקטורות מתקדמות של למידה עמוקה. בעוד שהשיטות המסורתיות הוגבלו בשל עלויות חישוביות גבוהות ודרישה למספר רב של דגימות, רשתות קונבולוציה (CNNs) הציגו ביצועים עדיפים משמעותית בהתמודדות עם קשרי דליפת מידע מורכבים ולא-ליניאריים בעקבות ההצפנה. חקר הארכיטקטורות המתקדמות הללו נשען על מספר עבודות בתחום:

ראשית, על מנת להתמודד עם אמצעי נגד חומרתיים כגון מיסוך (Masking) ורעשים, הוצג השימוש בארכיטקטורת Multi-Task CNN. בעבודתם של מארקט ואוסוולד[1] (Marquet and Oswald, 2024), מודגמת גישת למידה מרובת-משימות (MTL) המשתמשת בשיתוף משקולות קשיח – Hard Parameter Sharing. גישה זו מאפשרת לרשת ללמוד את כל בתי המפתח בו-זמנית, לזהות מבנים כלליים של הקלט, ולהקטין את הרעש על ידי מיצוע המשימות השונות. חסרונה המרכזי של שיטה זו לצרכינו הינו הצורך במידע פנימי על מבנה המיסוך.

שנית, מחקרם של פודל ורחימי (Poudel and Rahimi, 2025) [2] מספק בסיס להעדפת ResNets על פני רשתות CNN סטנדרטיות. עבודתם מראה כי רשתות CNN סובלות לעיתים קרובות מבעיית היעלמות הגרדיאנט (Vanishing Gradient) ומתקשות להכליל למאגרי נתונים עם מפתחות משתנים – Variable Key. לעומת זאת, שילוב של חיבורי שאריות (Residual Connections) ברשתות ResNet משפר את זרימת הגרדיאנטים ומאפשר למודל ללמוד בהצלחה להכליל מפתחות משתנים ולהתכנס מהר יותר.

לבסוף, נבחנו גישות מבוססות Transformers דרך מודל GPAM – Generalized Power Analysis Model שהוצג על ידי בורשטיין ואינברניצי (Bursztein and Invernizzi, 2024) [3]. מודל זה משתמש ב-Temporal Patchification כדי להתמודד עם רצפי דגימות ארוכים, ומחליף את שכבות חילוץ המאפיינים המסורתיות במנגנוני Attention המאפשרים למידה של קשרים ארוכי-טווח. עם זאת, חסרונה של שיטה זו הוא שהיא מצריכה לרוב אימון "קופסה לבנה" (White-Box), הדורש גישה לתוויות המיסוך (Masks) הפנימיות.

עבודות אלו מהוות את התשתית התיאורטית לפיתוח ארכיטקטורה משולבת בפרויקט, המבקשת לקחת את יתרונות ה-MTL וה-ResNet אך להישאר במגבלות של תקיפת "קופסה שחורה".

3. רקע תיאורטי

3.1. תקן הצפנת AES

Advanced Encryption Standard (AES) הינו תקן הצפנת בלוקים סימטרי המשמש היום בסטנדרט לאבטחת נתונים. האלגוריתם, בתצורתו הבסיסית, פועל על קלט (טקסט גלוי – Plaintext) בגודל קבוע של 16 בתים (128 ביטים), המסודרים במטריצה דו ממדית של 4×4 המכונה State Matrix. תהליך ההצפנה מורכב ממספר מחזורים (Rounds) – בדרך כלל 10 מחזורים עבור מפתח של 128 ביט – כאשר כל מחזור כולל ארבע פעולות מתמטיות ולוגיות:

1. SubBytes (SBox): החלפה לא לינארית של כל בית במטריצה.
2. ShiftRows: הזזה מעגלית של עמודות המטריצה.
3. MixColumns: עירבוב לינארי של עמודות המטריצה.
4. AddRoundKey: חיבור XOR של מטריצת המצב עם תת-מפתח ייעודי לאותו מחזור.

3.2. נקודות התורפה לדליפת מידע בהצפנת AES

בהקשר של תקיפות ערוצי צד (Side-Channel Analysis), צופן ה-AES נחשב לבעל "נקודת תורפה" קלאסית הממוקמת בסיבוב ההצפנה הראשון, וספציפית בפעולת ה-SBox.

קיימות מספר סיבות לכך ששלב זה מניב את הדליפה המשמעותית ביותר עבור התוקף:

- קשר ישיר למידע גלוי: בסיבוב הראשון, הפעולה הראשונה המבוצעת היא חיבור XOR בין הטקסט הגלוי לבין המפתח הסודי - $p \oplus k$. מיד לאחר מכן, התוצאה מוזנת לפונקציית ה-SBox, כך שהפלט הוא $s_1 = SBox[p \oplus k]$. משוואה זו קושרת באופן ישיר בין מידע גלוי, חלק מהסוד (בית בודד של המפתח), ותוצאת ביניים.
- אי לינאריות: ה-SBox היא הפונקציה הלא לינארית היחידה באלגוריתם ה-AES (מבוססת על הופכי כפך בשדה גלואה $GF(2^8)$). משמעות הדבר היא ששינוי של ביט אחד בקלט מוביל לשינוי משמעותי ובלתי צפוי במספר רב של ביטים בפלט.
- חתימה פיזיקלית: מבחינה חומרתית, כאשר המיקרו-בקר משחב את פלט ה-SBox וכותב אותו לרגיסטר או לא פיק נתונים כלשהו, פעולה זו צורכת הספק חשמלי התלוי ישירות בערך הנכתב (למשל, ביחס ישר למספר הביטים הנדלקים – Hamming Weight). החלפה לא לינארית גורמת לכך שערכי מפתח שגויים יובילו לפיזור הספק אקראי לחלוטין, בעוד שהמפתח הנכון ייצר חתימת הספק עקבית התואמת למודל הפיזיקלי.

לפיכך, על ידי השערת כל 256 ערכי בית המפתח האפשריים – k, יכול התוקף לחשב את פלט ה-SBox הצפוי לכל טקסט גלוי, ולהצליב אותו מול צריכת ההספק הפיזית שנצרכה בפועל. "דליפה" זו מהווה את האות הפיזיקלי שמנגנוני המיסוך מנסים להסתיר.

3.3. מקורות דליפה במיקרו מעבדים והשפעת מנגנון המיסוך

צריכת ההספק הרגעית של מיקרו-בקר נגזרת ישירות מהנתונים שהוא מעבד בכל הרגע נתון. במיקרו-בקרים (כגון ה-Atmega8515, עליו מתבסס מאגר המידע בפרויקט זה), מקור הדליפה המרכזי נובע ממעברי מצב באפיק הנתונים (Data Bus Transitions). כל פעולת קריאה או כתיבה משנה את מצבו של האפיק, כאשר כל ביט שמשנה את מצבו מוביל לפריקה או טעינה של קיבול פרזיטי. תהליך זה גורר קפיצת זרם הפרופורציונלית למספר הביטים שהתהפכו (בהתאם למודל Hamming Distance). מקורות דליפה נוספים כוללים גישה לזיכרון SRAM וכתיבה לרגיסטרים, למשל בעת שמירת פלט ה-SBox.

במימוש תקן AES שאינו מוגן (Unmasked), ערכי הביניים של ההצפנה (כגון s_1) מעובדים בצורה ישירה, ולכן נקודת זמן בודדת בעקבת ההספק עשויה להדליף מידע רגיש אודותיהם. לעומת זאת, במימוש הכולל הגנה מסדר ראשון (כדוגמת הגנה של מיסוך בוליאני בה נעסוק בפרויקט זה), המערכת אינה פועל ישירות על s_1.

במקום, מוגרלת מסכה אקראית (Mask), והמערכת מבצעת את החישובים על הערך הממוסך ($s_1 \oplus mask$). מכיוון שהמסכה והערך הממוסך מעובדים בנקודות זמן שונות, כל דגימה בעקבה בפני עצמה נראית אקראית ואינה מספקת מידע על הערך הסודי.

על מנת לחלץ מידע במקרה של מימוש מוגן של AES, התוקף נדרש לשלב שתי נקודות זמן שונות בעקבה – האחת מכילה דליפת מידע על המסכה, והשנייה על הערך הממוסך. רק ההתפלגות המשותפת שלשתי הנקודות הללו תלוי בערך הסודי s_1.

4. פיתוח המודל הנבחר

4.1. ניתוח יחס אות לרעש ומאפייני מערך הנתונים ASCAD_r

על מנת לאמוד במדויק את כמות המידע שנושאת כל דגימה בעקבה ביחס לערך המטרה, נעשה שימוש ביחס אות לרעש (SNR). המדד בוחן האם קיימת חתימה סטטיסטית בולטת בעקבות כאשר ערכי המטרה משתנים.

מתמטית, ה-SNR מסדר ראשון עבור נקודת זמן t וערך מטרה s (הנע בין 0-255) מוגר כך:

$$SNR(t) = \frac{Var_s(\mathbb{E}[trace(t)|s])}{\mathbb{E}_s(Var[trace(t)|s])}$$

כאשר המונה מייצג את האות (שונות הממוצעים המותנים של העקבות עבור כל ערך אפשרי של s), והמכנה מייצג את הרעש (הממוצע של השונויות הפנימיות בתוך כל קבוצת ערכים).

בבחינת ה-SNR מסדר ראשון (First Order SNR) על מאגר המידע ASCAD_r, התוצאות מאששות את האפקטיביות של מנגנון המיסוך: כפי שניתן לראות באיור 11 (בפרק הנספחים), בעוד שבתים 0 ו-1 הציגו ערכי SNR גבוהים משום שעובדו לפני תחילת המיסוך, בתי המפתח 2-15 הציגו SNR מסדר ראשון נמוך, הנושק לרצפת הרעש. זאת בניגוד ל-SNR מסדר ראשון המתקבל עבור מאגר מידע הנדגם על פני מצפין שאינו ממסוך, כפי שניתן לראות באיור 10 (פרק נספחים), שם ניתן לראות בבירור את האות מעל סף הרעש. נתון זה מוכיח כי התקפות מסדר ראשון על בתי אלו נידונו לכישלון עבור מצפין ממוסך, לכן הפרויקט מתמקד בחילוץ ערכי בתים הממוסכים.

על מנת לאתר את הדליפה מסדר שני (Second Order SNR – SO-SNR), ישומה טכניקת מכפלה ממורכזת (Centered Product) המשלבת זוגות של דגימות זמן t_1 -t_2 כדי לנטרל את הרכיב מסדר ראשון. פעולה זו מחושבת כך:

$$cp(t_1, t_2) = \big(trace(t_1) - \mu(t_1)\big) \cdot (trace(t_2) - \mu(t_2))$$

כאשר $\mu(t)$ הוא הממוצע של הדגימה בנקודת הזמן t על פני כל העקבות. המכפלה קושרת את המומנט המשותף מסדר שני. לאחר מכן, ה-SNR מסדר שני (SO-SNR) מחושב על ידי נוסחת ה-SNR הסטנדרטית על מאפייני המכפלה שנוצרו:

$$SO - SNR(t) = \frac{Var_s(\mathbb{E}[cp(t_1, t_2)|s])}{\mathbb{E}_s(Var[cp(t_1, t_2)|s])}$$

לאור ארוכן הרב של העקבות (250,000 דגימות), חישוב ה-SO-SNR בוצע על בסיס 200 חלונות מיצוע. התוצאות, כפי שניתן לראות באיור 12 (פרק נספחים) העידו כי קיימת דליפה מסדר שני עבור כל הבתים הממוסכים, כאשר עבור רובם, זוגות החלונות שהניבו את ה-SNR המקסימלי הורכבו מחלון אחד בטווח 88-143 וחלון שני בטווח 155-185.

כדי להבין היכן בדיוק מתרחשים אירועי ההדלפה בציר הזמן המקורי, תורגמו מספרי החלונות חזרה לדגימות זמן. מכיוון שהעקבה חולקה ל-200 חלונות שווים, כל חלון מייצג קטע של $\frac{250K}{200} = 1250$ דגימות. ולכן:

- מיקום עיבוד המסכה: טווח השיא הראשון נע סביב חלון מספר 100, אזי הדליפה אודות המסכה מתרחשת סביב הדגימה $100 \cdot 1250 = 125{,}000$.
- מיקום עיבוד הערל הממוסך: טווח השיא השני נע סביב חלון מספר 170, אזי הדליפה אודות הערך הממוסך מתרחשת סביב הדגימה $170 \cdot 1250 = 212{,}500$.

המסקנה הנגזרת מכך היא ששלד הרשת חייב להיות בעל שדה קליטה (Receptive Field) רחב מספיק על מנת לגשר על הפער בין שני האירועים.

עוד ניתן לשים לב באיור 12 (פרק נספחים), כי ה-SO-SNR של בתים 7 -12 חלש משמעותית לעומת שאר הבתים, ועל כן ניתן להסיק כי המודל יתקשה לנבא את ערכם. ישנן סיבות שונות אשר יכולות לעמוד בבסיס הבדל זה, לדוגמא צורת הניהול של הרגיסטרים והזיכרון – ייתכן כי בבתים 7 ו-12 מתרחש spill לרגיסטרים לאור מחסור במקום והתחלת כתיבה לזיכרון, דבר שייצור דפוס אחר בצריכת ההספק ועלול להוביל לטשטוש האות. ישנם גורמים נוספים רבים אשר יכולים לגרום לעיוות זה, אך לא זה מיקוד הפרויקט.

4.2. מודל ראשוני

העבודה העומדת במרכז פרויקט זה, היא זו של מארקט ואוסוולד (Marquet and Oswald, 2024) [1]. זאת לאור ההנחה כי המודל המוצג בה מקרב אותנו למטרה של מודל "קופסה שחורה", בו לא נצטרך שימוש בתוויות פנימיות של תהליך ההצפנה, או בידע על מבנה פנימי של ההצפנה. המודל המוצג במאמר זה דורש מידע פנימי על המבנה, בפרק זה נעסוק בעקיפת צורך זה ויצירת מודל מכליל המסתמך בבסיסו על מאמר זה.

4.1.1. מודל Multi-Task מבוסס ResNet

בשלב זה של הפרויקט, המיקוד היה בתקיפת הצפנת AES בעלת מיסוך בוליאני. הארכיטקטורה הראשונית שנחקרה במסגרת הפרויקט התבססה על תשתית של למידה מרובת משימות ובחנה את השפעתם של רכיבי רשת שונים על יכולת המודל לתקוף הצפנה ממוסכת, זאת בהתבסס על ארכיטקטורה אשר נחקרה בעבודתם של מארקט ואוסוולד (Marquet and Oswald, 2024) [1]. במחקר זה, לא התמקדו בשני הבתים הראשונים של המפתח, עובדה העולה בקנה אחד עם ניתוח ה-SNR לפיו הם אינם ממוסכים כלל ומציאתם פשוטה.

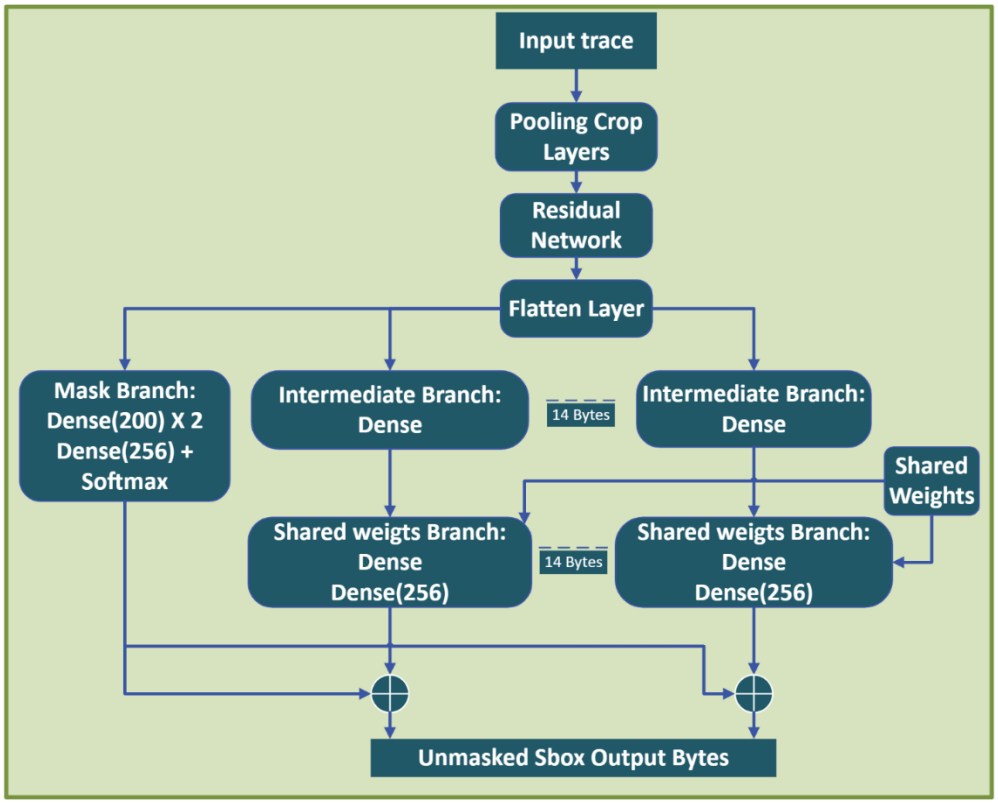

איור 1 – מודל לתקיפת מיסוך בוליאני

1. עיבוד מקדים והחלפת שלד ה-CNN ב-ResNet: קלט הרשת כלל עקבות הספק ארוכות שעברו תחילה דרך שכבות Pooling Crop.

- הגבלות ה-CNN: במאמר [1] נבחן שלד מבוסס CNN סטנדרטי, עם תוצאות טובות בחילוץ המפתח הסודי. עם זאת, התוצאות במחקרם פודל ורחימי (Poudel and Rahimi, 2025) [2] הראו את מגבלות רשת ה-CNN אל מול ResNet בהקשר Vanishing Gradients, ולכן היוו אינדיקציה לחולשה פוטנציאלית בשימוש ב-CNN במודל המוצג במאמר [1].
- המעבר ל-ResNet: שלד הרשת הוחלף ב-ResNet. חיבורי השארית אפשרו זרימה טובה יותר של גרדיאנטים, דבר שאפשר למודל להכליל בהצלחה מפחות משתנים, להתכנס מהר יותר ואף לצמצם את כמות העקבות הנדרשות לחילוץ מוצלח של מפתח ההצפנה (איורים 4 ו-5 בפרק התוצאות).

2. למידה מרובת משימות ושיתוף משקולות קשיח: פלט השלד הושטח והוזן למבנה של ראשי חיזוי מרובי-משימות, שנועד לחזות את כל בתי המפתח בו זמנית.

- הארכיטקטורה יישמה שיתוף פרמטרים קשיח ברמת השלד (כל בתי המפתח מוזנים לראשים לאחר אותו שלד) ושיתוף משקולות בין ענפי הביניים של הבתים השונים.

- מטרת השיתוף הייתה ללמוד את המבנה הכללי של הקלטים, לנצל מאפיינים משותפים בין הבתים, ולהוריד את רמת הרעש על ידי מיצוע המשימות.

3. ענף המיסוך ופעולת ה-XOR הקשיחה: טרם הפיכת המודל ל"קופסה שחורה", הארכיטקטורה כללה רכיבים ייעודיים לטיפול במיסוך:

- המבנה כלל ענף ייעודי לחיזוי המסכה (Mask Branch) שהורכב משכבות Dense ופונקציית Softmax, לצד ענפי ביניים לערכים ממוסכים.
- הפלטים של ענפים אלו אוחדו באמצעות פעולת XOR קשיחה בקוד (Hard-Coded) כדי לשחזר את פלט ה-SBox הלא ממוסך. מבנה זה דרש למעשה תלות בנתונים פנימיים על אופן המימוש, שכן על אופן המיסוך להיות ידוע מראש לתוקף.

4.1.2. המעבר לגישת ה"קופסה השחורה"

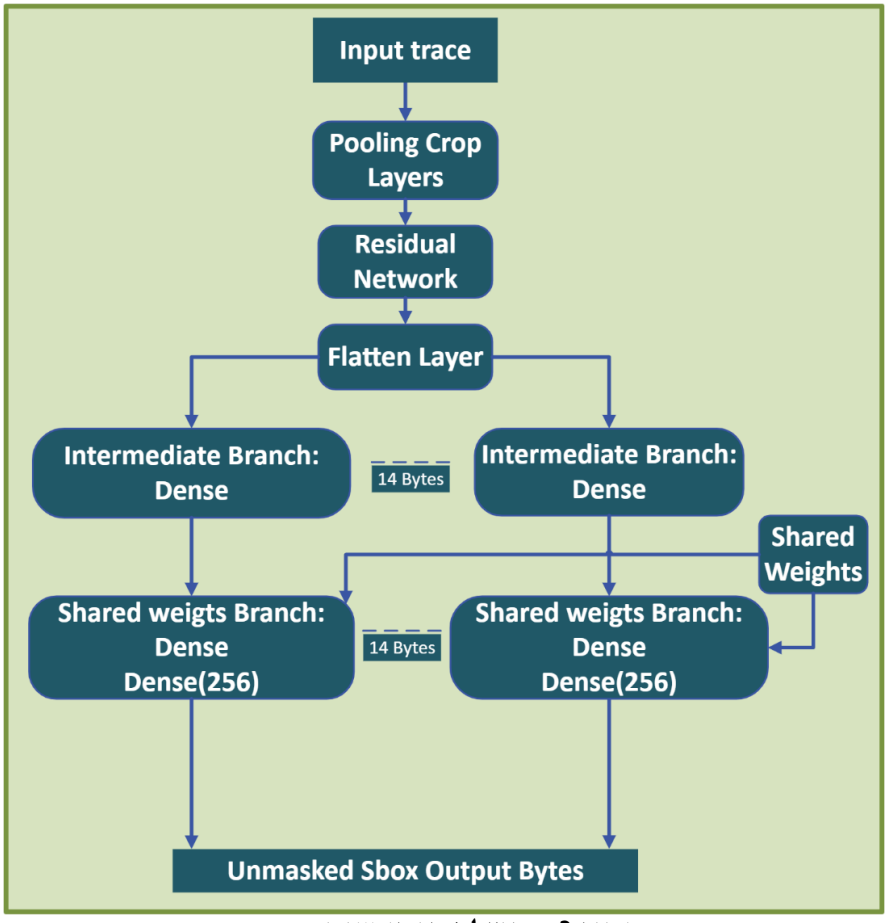

איור 2 – מודל גנרי ראשוני

- הסרת ה-XOR וענף המסכה: כאשר ענף המסכה ופעולת ה-XOR הקשיחה הוסרו, המודל התקשה ללמוד. ללא הכוונה קשיחה, המודל החל לבצע "שינון" של הנתונים מה שהוביל ל-Overfitting (איור 6 בפרק התוצאות).
- הוספת רגולריזציית L2 והעמקת שלד הרשת: כדי להתגבר על התאמת היתר, שלד ה-ResNet הועמק והוספה רגולריזציית L2. צעד זה אמנם הפחית משמעותית את התאמת היתר, אך המודל עדיין לא הצליח ללמוד את חוקיות הסרת המיסוך נכונה.

הממצאים, כפי שמתוארים בפרק הבא של דו"ח זה (איורים 4 ו-5), הוכיחו כי בעוד שלד ה-ResNet הוא קריטי ליכולת ההכללה ולזרימת הגרדיאנטים, עצם הסרת שכבות המיסוך הייעודיות גורמת למודל לקרוס.

המסקנה המרכזית הייתה שנדרש תכנון מחדש של הארכיטקטורה, וספציפית פיצוח של שכבות חדשות שיוכלו להחליף את פעולת ה-XOR הקשיחה ולאפשר למידת קשרים מורכבים.

4.3. שלבי פיתוח מודל סופי

תהליך הפיתוח של המודל הסופי כלל ארבעה שלבים עיקריים שבחנו ארכיטקטורות שונות להתמודדות עם בעיית המיסוך, ללא שימוש במידע פנימי.

שלב 1 – חיזוי ישיר

- ארכיטקטורה: מודל בעל ענף חיזוי יחיד, ללא כל שכבת קומבינציה בין ענפים (איור 2).
- רציונל: ניסיון לאלץ את המודל ללמוד ולחזות ישירות את פלט ה-SBox הלא ממוסך מתוך העקבות של ההצפנה הממוסכת.
- תוצאה: המודל נכשל. ענף יחיד אינו מסוגל לבצע את ההפרדה בין הערך למסכה, והמודל הציג התאמת יתר קיצונית או ניחוש אקראי (איור 6 בפרק התוצאות).

שלב 2 – קומבינציית רשת MLP

- ארכיטקטורה: מעבר למודל בעל שני ענפים (כל ענף בעל ערוצים שונים לבתי המפתח). פלטי שני הענפים עברו פונקציית אקטיבציה מסוג Softmax, שורשרו יחד והוזנו לתוך רשת MLP שכללה שכבות המשתפות משקולות בין הבתים השונים של הפתח.
- רציונל: ניסיון לשחזר את פעולת ה-XOR על ידי רשת MLP, תוך הנחה כי הענפים יקבלו תפקידים משלימים – למשל שענף אחד יילמד את המסכה והשני את הערך הממוסך.
- תוצאה: המודל נכשל. שרשור הסתברויות דרך MLP סיפק גרדיאנטים בלתי-תלויים לכל ענף. ללא תלות הדדית בגרדיאנטים, לא היה לענפים אפשרות להתמחות בתפקידים משלימים (כפי שציינו לעיל), כך שהמודל לא הצליח להכליל את הנתונים.

שלב 3 – קומבינציה בילינארית על פלטי Softmax

- ארכיטקטורה: שילוב שכבת קומבינציה בילינארית מבוססת Canonical Polyadic Decomposition, או CPD, במקום שכבת ה-MLP מהשלב הקודם, וזאת על פני פלטי Softmax של שני הענפים.
- רציונל: פעולת ה-XOR של המיסוך היא פעולה בילינארית, ולכן המודל המבוסס על CPD, מתאים מתמטית ללמוד אותה.
- תוצאה: המודל נכשל. מאחר שפלטי ה-Softmax באתחול של שני הענפים הם מסדר גודל של $O(\frac{1}{256})$, המכפלה הבילינארית שלהם יצרה ערכים מסדר גודל של $O(\frac{1}{256^2})$. הגרדיאנטים נעלמו והמודל נשאר מקובע על התפלגות הסתברויות אחידה.

שלב 4 – קומבינציה בילינארית על Logits גולמיים

זהו השלב הסופי, אשר פתר את הכשלים של השלב הקודם, עליו נפרט בהרחבה בחלקו הבא של הדו״ח.

4.4. המודל הנבחר

מודל אגנוסטי למיסוך מבוסס למידה עמוקה (Mask-Agnostic DL-SCA)

בסקר הספרות שנעשה במסגרת הפרויקט, בלט הנושא של שימוש במידע פנימי של מימוש ההצפנה על מנת לגרום למודלים להתכנס. מידע זה בא לידי ביטוי הן במידע על מבנה ההצפנה, או תוויות ערכים פנימיים של מנגנוני הגנה בין שלבי ההצפנה – מסיכות. מידע זה אינו נגיש במקרים רבים לתוקף המנסה לחלץ מידע מתוך מצפין, והשגת מידע זה דורשת לעיתים רבות פעולות פולשניות ויקרות מצד התוקף, ואף לא תמיד אפשריות.

הפתרון שנבחר לפרויקט מציג ארכיטקטורת "קופסה שחורה" (Black-Box) מבוססת למידה עמוקה, המיועדת לחלץ מפתחות סודיים של תקן AES מתוך עקבות הספק (Power traces) או חתימה אלקטרומגנטית (EM), וזאת ללא כל ידע מוקדם על אופן המימוש או על פעולות המיסוך (Masking) הפנימיות לעומת המודלים המובילים לפי סקר הספרות. הפתרון מבוסס על שלד ResNet לחילוץ מאפיינים, ולמידה מרובת משימות עם שיתוף פרמטרים בין כל הבתים של המפתח.

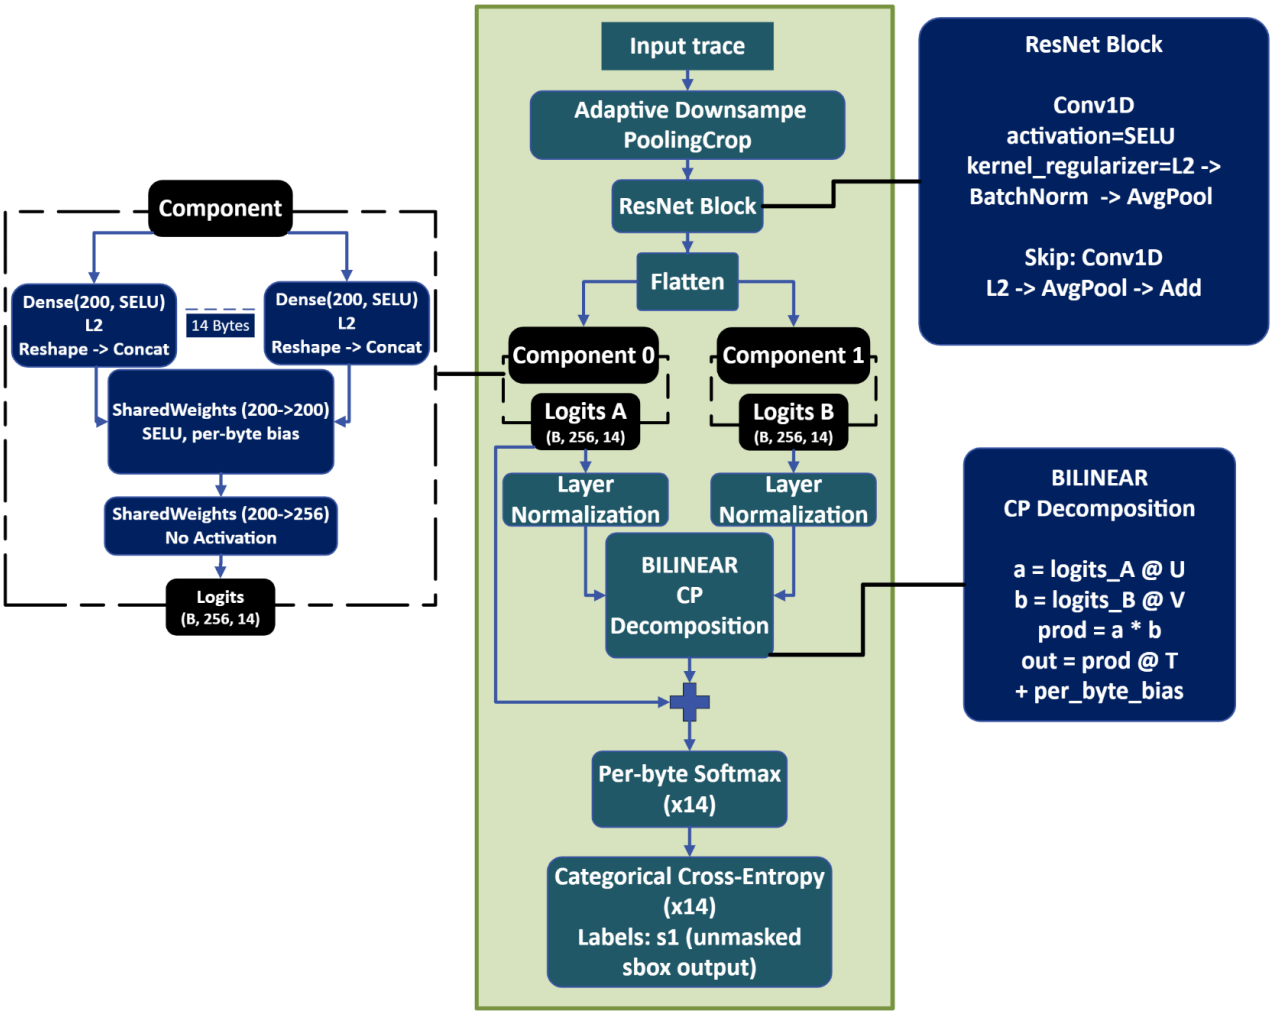

איור 3 - הפתרון הנבחר

1. **עיבוד מקדים (PoolingCrop)**
השכבה מבצעת דגימה מורדת (Downsampling) עם חלון חיתוך קבוע. הפעולה מורכבת מהכפלה איבר-איבר עם וקטור משקולות, העברה דרך AveragePooling1D, נרמול BatchNorm ולבסוף AlphaDropout.

2. **שלד מבוסס RestNet**
מסקר הספרות עולה כי רשתות CNN סטנדרטיות הראו מוגבלות ביכולת ההכללה שלהן (במיוחד מול מפתחות משתנים), וסבלו מתופעת Vanishing Gradient, נבחר שלד מבוסס ResNet. העקבות הגולמיות עוברות תחילה דגימה אדפטיבית (Adaptive Down-sampling) באמצעות שכבות PoolingCrop נלמדות, המצמצמות את אורך העקבה תוך סינון אזורים לא רלוונטיים. לאחר מכן,

הנתונים מוזמנים לשלד מבוסס ResNet המשמשת כמחלץ מאפיינים משותף לכל בתי מפתח ההצפנה.

- הבלוק המרכזי מורכב משכבות Conv1D המלוות בפונקציית אקטיבציה מסוג SELU, נרמול (BatchNorm) ושכבת AvgPool.
- במקביל, קיים Skip Connection הכולל קונבולוציה מותאמת ו-AvgPool, המתחבר לפלט המרכזי באמצעות פעולת חיבור (Add). מבנה זה מבטיח זרימת גרדיאנטים רציפה ומונע את תופעת Vanishing Gradient המאפיינת רשתות עמוקות.

3. למידה מרובת משימות – Multi-Task-Learning – ושיתוף משקולות

הבסיס לארכיטקטורה הוא שימוש בלמידה מרובת-משימות (MTL) המיישמת הן שיתוף פרמטרים קשיח על ידי שלדה משותפת לכל הבתים של מפתח ההצפנה, והן שיתוף פרמטרים נלמדים של השכבות המתמחות בבתים הספציפיים בקצה המודל. פלט השלד מושטח (Flatten) ומתפצל למספר רכיבים (Components). כל רכיב מפעיל ראשי חיזוי מרובי-משימות עבור כל בתי המתח במבנה זהה אך עם משקולות נפרדות:

- שכבת Dense ייעודית לכל בית: כל בתי המפתח עוברים במקביל תחילה דרך שכבת Dense נפרדת בעלת משקולות פרטיות עם שכבת אקטיבציה SELU, המאפשרת למודל ללמוד אילו מאפיינים ספציפיים מתוך השלד רלוונטיים למיקום הדליפה של כל בית.
- שכבות SharedWeightsDenseLayer: הפלטים של השכבות הייעודיות עוברים דרך שכבות בעלות משקולות משותפות (Shared W matrix) עם הטיות (Biases) נפרדות לכל בית. מבנה זה כופה סימטריה מבנית המשקפת את פעולת ה-SBox הזהה של AES עבור כל הבתים, ומהווה מנגנון רגולריזציה המקטין את כמות הפרמטרים הנדרשת. השכבה הסופית מפיקה בשלב זה Logits גולמיים עבור 256 הערכים האפשריים ללא פונקציית אקטיבציה, וזאת על מנת לאפשר גרדיאנט משמעותי במהלך הלמידה.
- תוצר הרכיבים: במסגרת הפרויקט הוחלט להשתמש בשני רכיבים (רכיב 0 ורכיב 1) בעלי התוצר Logits_A, Logits_B. המבנה הכפול והבלתי-תלוי הזה מאפשר למודל לפתח ייצוג נפרד עבור הערך הממוסך וייצוג עבור המסכה עצמה.

4. שכבת Bilinear-Combiner מבוססת CPD (Canonical Polyadic Decomposition)

האתגר המרכזי במימושים הקודמים היה התלות בשכבות ייעודיות למיסוך (כגון פעולת XOR הכתובה ישירות בקוד המודל) שהובילה להתאמת-יתר (Overfitting) כאשר הוסרו. כדי לאפשר למודל ללמוד את פעולת הסרת המיסוך באופן טבעי מתוך הנתונים, הפלטים של שני הרכיבים (Logits_A & Logits_B) מוזנים אל שכבת קומבינציה בילינארית:

- השכבה פועלת על ה-Logits הגולמיים של שני הרכיבים, לאחר שעברו נרמול (LayerNorm) כדי למנוע חוסר יציבות נומרית. הפעולה על Logits חיונית למניעת קריסת הגרדיאנט האופיינית למכפלת הסתברויות Softmax – $O(1)$ במקום $O(\frac{1}{256^2})$ ברמת הדעיכה.
- השכבה מיישמת פירוק טנזורים מדרגה R. במקום להשתמש בטנזור משקולות W מלא ממימד $256 \times 256 \times 256$ אשר יקר מבחינה חישובית, השכבה מקרבת את הפעולה הבילינארית בצורה הבאה:

$$W[i,j,k] \approx \sum_{r=1}^{R} U[i,r] \cdot V[j,r] \cdot T[r,k]$$

כאשר U מחלצת מאפיינים מתוך ענף A, ו-V מחלצת מאפיינים מענף B. T

כלומר, ככל שנגדיל את הדרגה, כך נקבל קירוב איכותי יותר של הפעולה.

- בפועל, פעולת הקומבינציה מחושבת על ידי הכפלת מטריצות U ו-V ב-Logits של רכיב 0 ורכיב 1 (בהתאמה), ביצוע מכפלה איבר איבר, והכפלה במטריצה T (המוסיפה הטיה) כדי לחזור למרחב של 256 מחלקות:

$$Output = \left((Logits_A \cdot U) \odot (Logits_B \cdot V)\right) \cdot T + bias$$

- המכפלה איבר איבר יוצרת תלות הדדית ישירה בגרדיאנטים, שכן הגרדיאנט של ענף אחד תלוי בפלט של הענף השני. תלות זו מאלצת את רכיב 0 ורכיב 1 להתמחות וללמוד ייצוגים משלימים כדי לשחזר את הערך המקורי.

- מאחר שפעולת מיסוך מעל שדה גלואה GF(256) היא במהותה פעולה ביליניארית, שימוש בפירוק CP מאפשר ייצוג יעיל ולמידה של פונקציות ביליניאריות ישירות מתוך הנתונים.

- מטריצות הפירוק U(256,R), V(256,R), T(R(256 מאותחלות בשיטת GlorotUniform עם גרעין אקראי קבוע. וקטור ההטיה (Bias) לכל בית מאותחל באפסים.

- שכבה זו מייתרת את הצורך בפעולות מתמטיות הכתובות ישירות בקוד, ומשלימה את הפיכת המודל לאגנוסטי לחלוטין לסוג המיסוך (Masking-Agnostic), תוך מניעת קריסת הגרדיאנטים האופיינית לפעולות כפל.

5. **מנגנוני רגולריזציה ומניעת התאמת יתר**

כדי לייצב את האימון ולהבטיח שהמודל לומד חוקיות אמיתית ולא משנן את נתוני האימון (Overfitting) שולבו מספר מנגנוני תמיכה:

- Skip Connections: הוספת פלט Logits מהשלד ישירות לשכבת ה-Bilinear Combiner גורמת לכך שהוא יקבל גרדיאנטים שימושיים כבר מן ה-Epoch הראשון, לפני שישנה למידה משמעותית בשכבת הקומבינציה. המוצא המתקבל הוא: $output = bilinear(A, B) + logits_A$.

- הזרקת רעש גאוסי: הוספת רעש לעקבות המנורמלות במהלך האימון מאלצת את הרשת ללמוד חוקיות כללית ולא להתאים את עצמה לתבניות רעש ספציפיות בעקבות האימון.

- רגולריזציית L2: מופעלת רוגלריזציית L2 על שכבות הקונבולוציה וה-Dense כדי למנוע מפילטרים לפתח משקולות גדולות, מה שעלול לאפשר לרשת לבצע Overfitting ולייתר את שכבתת הקומבינציה.

- אימון ללא מידע לא נגיש: המודל מאומן תוך שימוש בתוויות של פלט ה-SBox ללא מיסוך בלבד, ואינו משתמש כלל בתוויות של מנגנון המיסוך (Mask labels) או של נתוני ביניים ממוסכים, וכך על המודל ללמוד את בעצמו את חלקיה הפנימיים של ההצפנה.

הפלט הסופי מחושב באמצעות שכבות Softmax נפרדות לכל בית, והמודל מאומן תחת פונקציית הפסד של Categorical Cross-Entropy תוך הסתמכות רק על תוויות ה-SBox ללא מיסוך, ללא התייחסות לנתוני ביניים או מבנה המיסוך.

מטרת מבנה זה להשיג מודל פשוט לשימוש מנקודת המבט של התוקף אשר אינו צריך לדעת את מבנה ההצפנה או את ערכיה הפנימיים בזמן אמת, אך בעל יכולת שבירה של הצפנת AES בצורה יעילה ומהירה.

5. תוצאות

פרק זה מציג את תוצאות הניסויים שבוצעו במהלך מציאת הארכיטקטורה אשר ענתה על הצרכים שלנו, עבור מודל "קופסה שחורה". התוצאות נבחנו על בסיס מדדי שגיאה (Loss), דיוק חיזוי (Accuracy), ומדד אנטרופיית הניחושים (Guessing Entropy – GE) המעריך את מספר העקבות הנדרש לשחזור המפח הסודי במלואו.

5.1. תוצאות ביניים: ResNet VS CNN

בשלב הראשון של הפרויקט, נבחנו ביצועי שלד המודל בחילוץ מאפיינים, בוצעה השוואה בין ארכיטקטורת CNN סטנדרטית לבין ארכיטקטורת ResNet בתצורה של ריבוי משימות (Multi-Task Learning).

להלן גרפים המתארים את אימון המודל מעבודתם של מארקט ואוסוולד (Marquet and Oswald, 2024) [1], בתצורתו המקורית (עם שלדת CNN) לעומת תצורת ResNet אותה מימשנו בשלבו הראשון של הפרויקט:

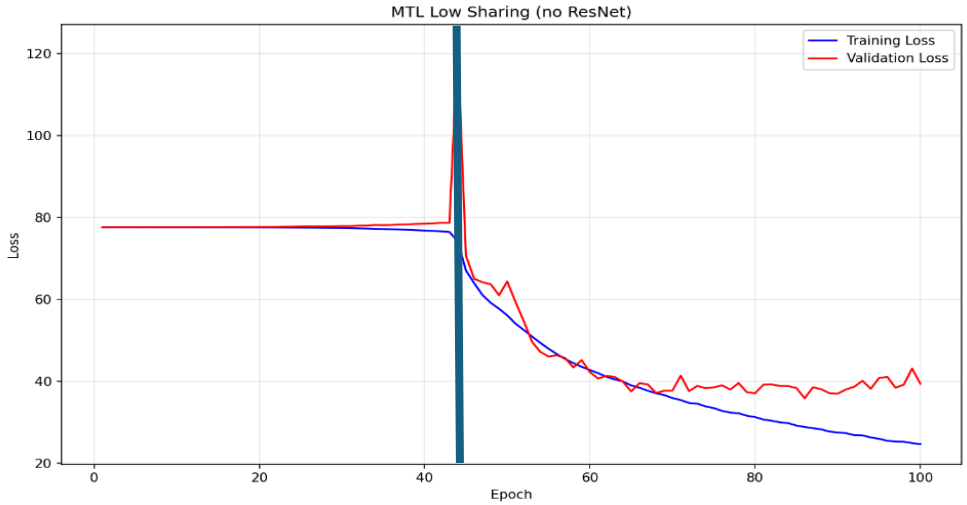

איור 4 – Training & Validation Loss VS Epoch עבור מודל הבסיס מתוך המאמר עם שלד CNN

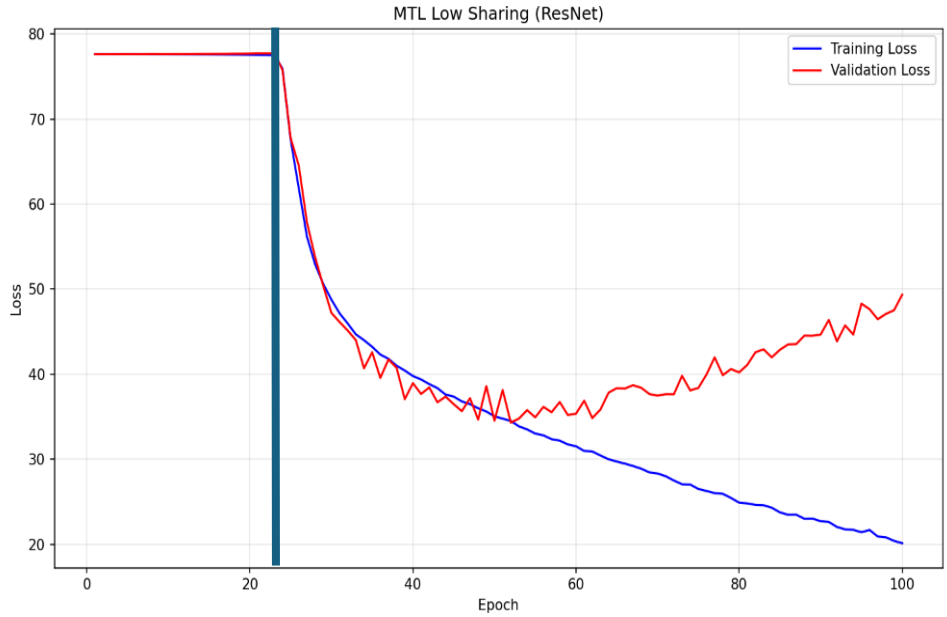

איור 5 – Training & Validation Loss VS Epoch עבור מודל הבסיס מתוך המאמר עם שלד ResNet

כפי שניתן לראות באיורים 4 ו-5 לעיל, שלד ה-ResNet שיפר משמעותית את יכולת ההכללה של המודל.
המודל מבוסס ה-ResNet הצליח לשבור את מישור הלמידה ההתחלתי (Plateau) מהר יותר באופן משמעותי,
נפילה אקספוננציאלית ב-Training Loss לאחר ~ 20 $Epochs$ לעומת ~ 40 $Epochs$ עם שלד CNN.

יתרה על כך, המעבר ל-ResNet הקטין בניסויים מסוימים את כמות העקבות אשר נדרשו על מנת לחלץ את מפתח ההצפנה.

5.2. ניסיון מימוש Black Box

כאשר הוסרו פעולת ה-XOR הקשיחה ושכבות המיסוך הייעודיות בניסיון ליצור מודל "קופסה שחורה" מלא, המודל התקשה ללמוד.

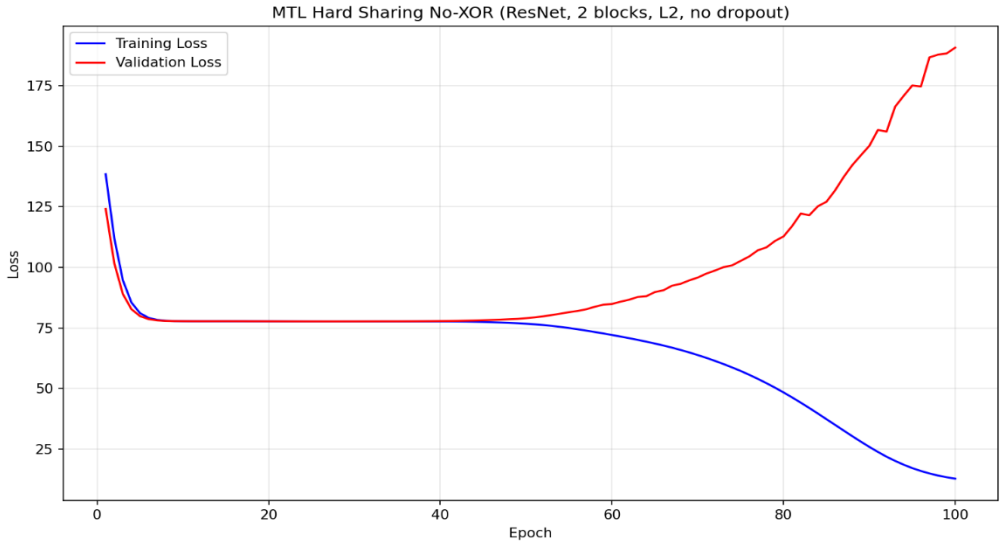

איור 7 – Training & Validation Loss VS Epoch מודל ראשוני ללא שכבות XOR

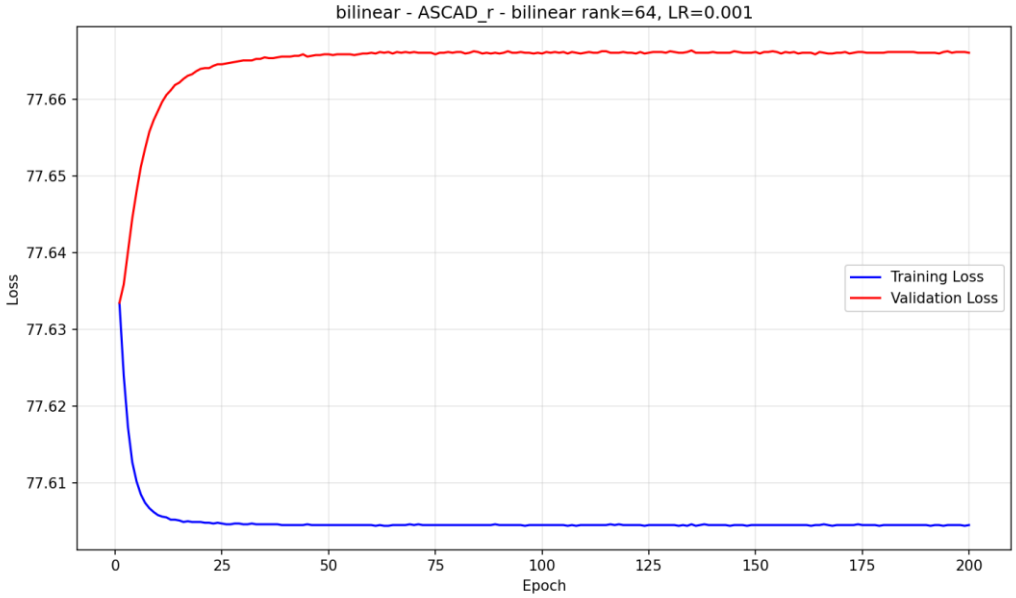

איור 6 – Training & Validation Loss VS Epoch עם שכבה בילינארית עם קלט Softmax

- שימוש בחיזוי ישיר וברשתות MLP: כאשר המודל ניסה לחזות ישירות את הפלט, או השתמש בקשת MLP לשילוב ענפים, הוא נטה להתאמת יתר משמעותית כפי שניתן לראות באיור 6. כלומר, בגישה זו המודל שינן את נתוני האימון ללא יכולת הכללה.
- הכשל של פונקציית Softmax: ניסיון מוקדם ליישם קומבינציה בילינארית על פלטי Softmax הוביל להעלמת גרדיאנטים. על פי כללי גזירת מכפלה, הרי ש - $\frac{\partial(a\cdot b)}{\partial\theta} = b\cdot\frac{\partial a}{\partial\theta} + a\cdot\frac{\partial b}{\partial\theta}$, כאשר ערכי ה-Softmax ההתחלתיים הם בסדר גודל של $O(\frac{1}{256})$, הגרדיאנטים מוכפלים בערכים זעירים וקורסים לסדר גודל של $O(\frac{1}{256^2})$, דבר שהשאיר את המודל במצב של ניחוש אקראי כפי שניתן לראות באיור 7 (הערכים נשארים בקירוב זהים לכל 200 Epochs. כדי למנוע קריסה זו, שכבת הקומבינציה הבילינאיארית תריכה להיות מוזנת מ- Logits גולמיים ולא מהסתברויות.

5.3. הארכיטקטורה הנבחרת

5.3.1. ניתוח למידת המודל הנבחר

הארכיטקטורה הסופית, המפעילה את שכבת הקומבינציה הבילינארית עם דרגה $R = 64$ על Logits גולמיים (פלט הענפים) בשילוב Skip Connection, רגולריזציית L2 והזרקת רעש גאוסי, פתרה את בעיות ההתכנסות.

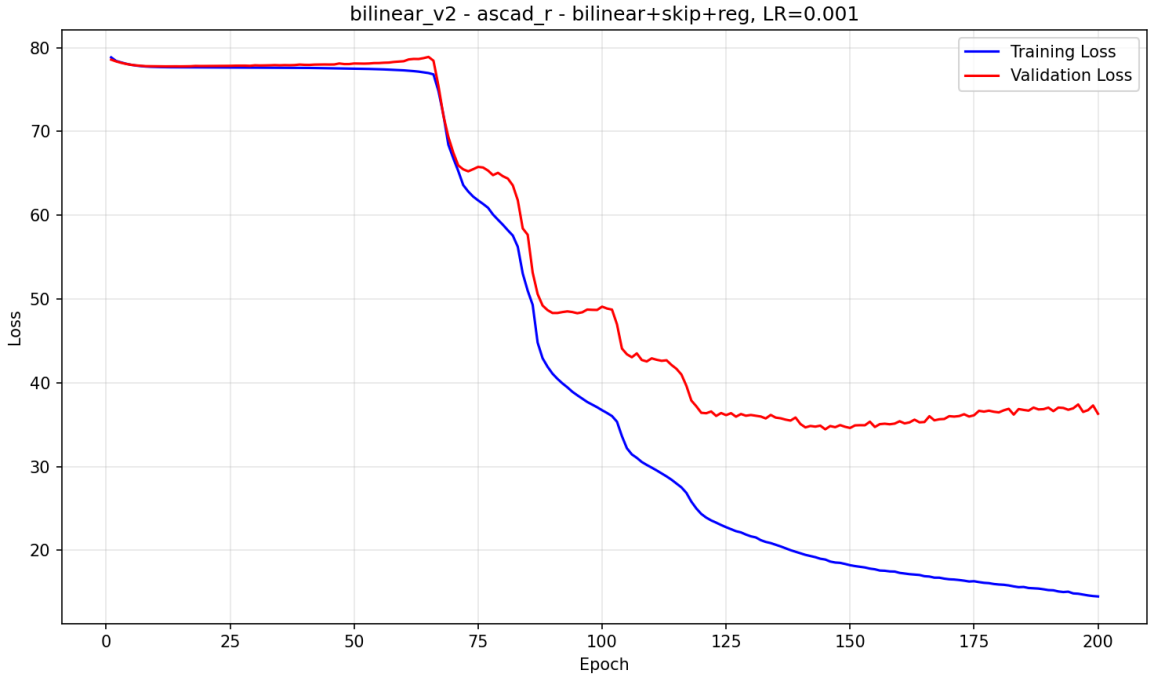

איור 8 – Training & Validation Loss VS Epoch עם שכבה בילינארית עם קלט Logits

מעקב אחר עקומת הלמידה באיור 8 חושף את השפעתם של רכיבי המודל לאורך זמן:

- Epochs 1-50: המודל חוזה באופן אקראי, אך ה-Skip Connection מאפשר לגרדיאנטים להתחיל לזרום וללמד את שלד ה-ResNet לחלץ מאפיינים.
- Epochs 75-100: המודל כבר לא מנחש אקראית וללמוד את פעולת המיסוך ההופכית, כאשר שגיאת האימון צונחת מתחת ל-40.
- Epochs 150-200: המודל מתכנס בהצלחה ומשיג דיוק אימון של 77.3% ודיוק ולידציה של 41.7%, המוכיח את יכולת ההכללה ללא התאמת יתר.

5.3.2. ניתוח תקיפת המודל הנבחר

על מנת לבחון בפועל את המודל שהתקבל, נבדקה יכולתו לשחזר את כל בתי המפתח הסודי בפועל על פני מאגר מידע המכיל עקבות של הצפנת AES בעלת מיסוך בוליאני, כפי שנעשה בעבודתם של מארקט ואוסוולד (Marquet and Oswald, 2024) [1]. מנגנון התקיפה בנוי כך:

- יהי N מספר העקבות המשמשות לתקיפה.
- תהי t_i עקבה באינדקס i.
- יהי p_i בית הטקס הגלוי (Plaintext byte) התואם לעקבה i.
- יהי $k \in \{0,1,\dots,255\}$ ניחוש אפשרי מתוך 256 האפשרויות לבית המפתח.

להלן השלבים המתמטיים של התקיפה:

1. חישוב השערת פלט ה-SBox:

עבור כל ניחוש מפתח k ולכל טקסט גלוי p_i, התוקף מחשב את הערך הלא ממוסך שהיה אמור לצאת מתיבת ה-SBox:

$$s_i = SBox[p_i \oplus k]$$

2. הסתברות משותפת:

המודל המאומן פולט התפלגות הסתברויות עבור עקבה נתונה. נסמן ב-$P_{model}(s|t_i)$ את ההסתברות שהמודל מייחס לערך ה-SBox, בהינתן העקבה t_i.

בהנחה שכל העקבות הן בלתי תלויות סטטיסטית, פונקציית הנראות (Likelihood) לכן שהניחוש k הוא המפתח הנכון בהינתן כל N העקבות, היא מכפלת ההסתברויות הבדידות:

$$L(k) = \prod_{i=1}^{N} P_{model}(s_i(k)|t_i)$$

3. המעבר להסתברות לוגריתמית מצטברת (Log-Likelihood):

מכיוון ש-P_{model} הוא מספר בין 0 ל-1, מכפלה של N מספרים כאלו תוביל במהרה להתכנסות לאפס. כדי לפתור זאת, מפעילים פונקציית לוגריתם.

מכיוון שהלוגריתם הוא פונקציה מונוטונית עולה, הוא שומר על יחסי הסדר, אך הופך את פעולת המכפלה לסכום נוח ויציב חישובית. זהו הציון המצטבר (Score) עבור כל ניחוש מפתח k:

$$Score(k) = \log\big(L(k)\big) = \sum_{i=1}^{N} \log\left(P_{model}(s_i(k)|t_i)\right)$$

4. בחירת המפתח וחישוב אנטרופיית הניחוש (Guessing Entropy):

המפתח נבחר על ידי התקיפה, k^*, הוא זה שממקסם את הציון הלוגריתמי המצטבר:

$$k^* = \arg_{k\in\{0,1,\dots,255\}} \max Score(k)$$

לאחר סיום מעבר הלולאה על כל העקבות, ממיינים את כל 256 האפשרויות של k לפי ה-$Score(k)$ שלהם בסדר יורד. אנטרופיית הניחוש (GE) מוגדרת פשוט בתור המיקום (Rank) של המפתח הסודי **הנכון** בתוך הרשימה הממוינת הזו. כאשר הציון של המפתח הנכון הוא $Rank = 1$, אנטרופיית הניחוש הינה אידאלית.

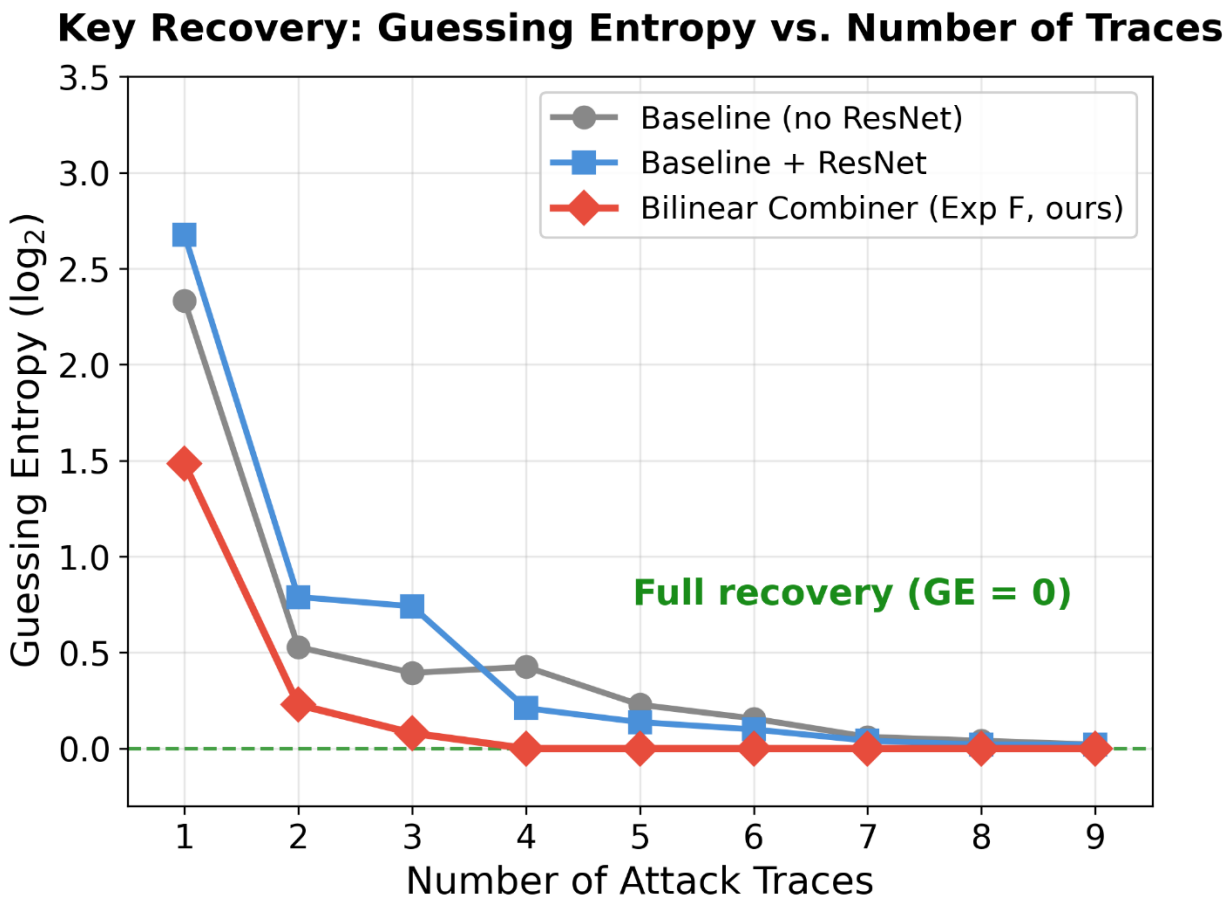

איור 9 Guessing Entropy VS #Traces, המודל הנבחר כנגד מודל הבסיס

איור 9 לעיל ממחיש את ביצועי חילוץ המפתח של המודל הנבחר בהשוואה למודל הבסיס, כפי שהוא במקור ועם החלפת בלוקי ה-CNN בבלוקי ResNet, על ידי מדידת אנטרופיית הניחוש (Guessing Entropy – GE) כפונקציה של מספר העקבות המשמשות לתקיפה.

מדד ה-GE מעריך את המיקום הממוצע של המפתח הסודי האמיתי בטבלת הניחושים של המודל. ערך 0 (כלומר log (1) מעיד על שחזור מלא, מצב שבו המודל מדרג את המפתח הנכון במקום הראשון בוודאות מוחלטת.

מניתוח הגרף באיור 9 עולות המסקנות הבאות:

- המודל שפותח בפרויקט (מסומן בקו אדום) מציג יתרון על פני מודל הבסיס. עבור כל מספר של עקבות בהן נעשה שימוש בתקיפה, המודל הנבחר דירג את המפתח הנכון יותר קרוב לדירוג ודאי לעומת מודל הבסיס, גם בהינתן שלד ResNet אשר מעבר למספר עקבות מסוים דירג את המפתח הנכון בדירוג טוב יותר ממודל הבסיס בעל שלד CNN.
- תוצאה ויזואלית זו מהווה הוכחה אמפירית לכך שהארכיטקטורה ה-"קופסה שחורה" אינה רק מייתרת את הצורך בידע מוקדם על מבנה ההצפנה ומיקום המסכות, אלא אף מפיקה מאפיינים סטטיסטיים איכותיים יותר לעומת מודל הבסיס, המקל על המודל בכך שחוסך ממנו את הצורך בללמוד את סוג ההצפנה.

לוגים נוספים של תוצאות התקיפה הינן בפרק הנספחים.

באיור 13 (נספחים) ניתן לראות כי גם בהינתן עקבה בודדת, הרי שהמודל מצליח לנחש נכונה את המפתח בחלק מהמקרים (31.7% – 67.2% מתוך 10K ניסויים, עבור עקבה בודדת). בתקיפות מפתח ישנה חשיבות רבה לצמצום מניית מרחב האפשרויות לערך המפתח, לכן אם המודל מאפשר לתוקף להניח כי הבית הנכון נמצא בין האפשרויות המדורגות גבוה בפלט המודל, הרי שזה מצמצם באופן משמעותי את מניית האפשרויות שעליו לנסות. כלומר, טבלה זו ממחישה כי גם בלי לסכום את ההסתברויות של כל בית על פני מספר עקבות, הרי שהוא מצליח להבין הייטב את הנתונים ולהכליל.

כפי שניתן לראות באיור 14 (נספחים), כאשר סוכמים את הסתברויות הבתים כפי שתואר לעיל, הרי שהמודל מצליח לחלץ את המפתח הסודי בהצלחה תוך מספר קטן של עקבות, העומד על 2-4 עקבות בלבד. ניתן לראות באיור 14 (נספחים) כי ביצועיו של מודל הבסיס עבור עקבה בודדת טובים פחות לעומת המודל הנבחר שפותח בפרויקט זה, למרות היות מודל הבסיס בעל משימת חיזוי פשוטה יותר לעומת המודל הנבחר – הוא אינו צריך לשחזר את פעולת ה-XOR ההופכית מפני שהיא כתובה בקוד באופן קשיח ואינה נלמדת.

כלומר, המודל הנבחר הצליח למדל באופן מוצלח את הקשרים המורכבים ללא ידע מקדים כלל על מבנה המיסוך וללא תוויות של מידע פנימי שאינו נגיש, כל זאת תוך השגת ביצועים טובים יותר לעומת מודל הבסיס אשר אינו בעל פוטנציאל הכללה למיסוכים נוספים.

באיור 13 (נספחים) ניתן לראות כי מודל הבסיס הצליח לשחזר את כל בתי המפתח, אך אף על פני מספר עקבות הפגין יכולת שחזור ירודה לעומת המודל הנבחר, שכן נדרשו עבורו יותר עקבות על מנת לשחזר את כל המפתח הסודי בהצלחה – 3-14 עקבות לעומת 2-4 עקבות עם המודל הנבחר. אזי, המסקנה העולה מאיור 15, נשארת בעינה ואף מחוזקת על ידי איור 16.

בנוסף, ניתוח תוצאות התקיפה מצביע על מגמה עקבי בתי המפתח 3, 6, 7 ו-12 מתגלים כקשים ביותר לחילוץ בכלל הארכיטקטורות שנבדקו (דבר שבא לידי ביטוי בצורך במספר רב יותר של עקבות להתכנסות או בדירוג מיקום גבוהה יותר). בחינת ערכי ה-SO-SNR מספקת הסבר חלקי לתופעה: הבתים 7 ו-12 התאפיינו ב-SO-SNR החלש ביותר, ולפיכך הקושי בחילוצם נובע מחולשתו של האות הפיזיקלי ככל הנראה. עם זאת, הבתים 3 ו-6 מחזיקים בערכי SNR בינוניים ועדיין מאתגרים את המודל. ניתן לשאר כי הקושי נובע כתוצאה מקשיים מבניים בהצפנה הנובעים מסדר הפעולות של ההצפנה אשר גורר שינויים בגישה לנתונים מסוים ולכן משנה את הופעת בעקבה וכך מקשה על חילוצם.

6. סיכום ומסקנות

6.1. סיכום

פרויקט זה הוכיח את ההיתכנות של פיתוח מודל תקיפת ערוצי צד (SCA) מבוסס למידה עמוקה, הפועל כ"קופסה שחורה" לחלוטין, ללא כל ידע מוקדם על אופן מימוש ההצפנה או הסתמכות על נתוני הביניים של ההצפנה עצמה. באמצעות שילוב שלד מבוסס ResNet המחלץ מאפיינים, המיישם למידה מרובת משימות (Multi Task Learning) ושכבת קומבינציה בילינארית נלמדת, המודל הצליח להחליף פעולות קשיחות של הסרת המיסוך, כגון XOR בו התמקדנו בפרויקט זה. הארכיטקטורה המוצעת השיגה ביצועים העולים על מודל הבסיס, והצליחה לשחזר את כל בתי המפתח הסודי של ההצפנה עם אנטרופיית ניחוש מושלמת תוך 2-4 עקבות בלבד.

6.2. תובנות

מתוך שלבי הפיתוח והממצאים האמפיריים, עולות מספר תובנות ארכיטקטוניות קריטיות לאימון מודלים לחילוץ מידע ממערכות ממוסכות:

- שלד הרשת כצוואר בקבוק: הדליפה מסדר שני אכן קיימת בנתונים עצמם, ולכן האתגר המרכזי של המודל הוא לאתר ונתב נכונה את המאפיינים עבור כל בית. לכן, השימוש ב-PoolingCrop יחד עם

רשת ResNet היה הכרחי על מנת ליצור שדה קליטה רחב מספיק שיוכל להתמודד עם פערי הזמן שהתגלו באנליזת הדליפה.

- יכולת הייצוג של פירוק CP: פעולת מיסוך, במקרים הנפוצים, מעל שדה גלואה $GF(256)$ היא במהותה פעולה בילינארית. הוכח כי פירוק טנזורים (CPD) בדרגה מספקת מסוגל ללמוד ולייצג בהצלחה פעולות אלו ישירות מתוך הנתונים, ובכך לייתר את הצורך בקידוד קשיח של חוקיות ההצפנה או בידע על מבנה המיסוך מראש.
- חשיבות זרימת הגרדיאנטים – שימוש ב- Logits לעומת Softmax: תובנה משמעותית מהפרויקט היא ששכבת הקומבינציה חייבת לפעול על Logits גולמיים עם נרמול כדי לשמר את זרימת הגרדיאנטים. ניסיונות להפעיל את הקומבינציה על הסתברויות Softmax גרמו לקריסת הגרדיאנטים לסדר גודל של $O(\frac{1}{256^2})$ ולכישלון המודל בעת הלמידה, בעוד שהלמידה על Logits שמרה על דעיכה מסדר גודל של $O(1)$.
- איזון בין למידה ושינון: הצלחת המודל נשענת על סינרגיה בין מספר רכיבים. מצד אחד, חיבור Skip Connection מוקדם היא הכרחית כדי לספק לשלד הרשת גרדיאנטים שימושיים כבר ב-Epoch הראשון. מצד שני, ללא רגולריזציית L2 והזרקת רעש גאוסי לעקבות, המודל נוטה להסתמך רק על ערוץ ה-Skip Connection כדי לשנן נתונים (Overfitting). הרגולריזציה מונעת זאת ומאלצת את הרשת להשתמש בשכבת הקומבינציה הבילינארית כדי למצוא פתרון אמיתי ומוכלל.
- קושי התקיפה כתכונה אינהרנטית של הנתונים: העובדה שירוד הקושי בחילוץ הבתים נותר עקבי על פני ארכיטקטורות שונות מצביעה על סבירות גבוהה לכך שחסם הביצועים המרכזי מושפע מהפיזיקה של השבב, מסדר העיבוד במימוש התוכנתי ומהתפלגות האותות בעקבה. נתון זה מאפשר להסיק כי הקושי בחילוץ בתים מסויימים אינו נובע בהכרח ממגבלה תכנונית של מודל הלמידה העמוקה בלבד, אלא משקף במידה רבה מגבלה אינהרנטית של רמת המידע המצויה בנתונים הפיזיקליים עצמם.

7. כיווני מחקר עתידיים

הישגי הפרוייקט פותחים פתח למספר כיווני המשך:

1. התאמה לסוגי מיסוך שונים: נדרש המשך כוונון של הארכיטקטורה והיפר-פרמטרים כדי להתמודד עם סכמות מיסוך מורכבות יותר, כגון מיסוך אפיני (Affine Masking), אשר עשויות לדרוש קונפיגורציות מודל שונות מאלו שהצליחו במיסוך בוליאני.
2. מעבר לארכיטקטורת Transformers: כיוון מחקר מבטיח הוא החלפת שלד ה-ResNet בשלד המבוסס Transformers. שימוש במנגנוני Attention עשוי לאפשר חילוץ מאפיינים איכותי יותר מתוך עקבות ארוכות ומורכבות יותר, ותיאורטית עשוי להקל על התאמת המודל מבחינה פרמטרית לכל מיסוך.
3. השפעת אופטימיזציית Compiler על פרופיל הדליפה: כיוון מחקר אפשרי העולה מתוך אנליזת ה-SNR הוא בחינת רגישות פרופיל הקושי לאופן קידוד התוכנה. מחקר עתידי יוכל לקמפל מחדש את קוד ההצפנה על גבי אותו מיקרו-בקר, אך תחתך הגדרות קומפילציה שונות (לדוגמה – ללא אופטימזיציה). שינויים אלו יובילו להקצאת רגיסטרים שונה, לתבניות גישה חלופיות לזיכרון, ולשינוי בסדר הפקודות האסמבלי. המטרה תהיה לבחון האם בתנאים אלו חל שינוי במידת הקושי בחילוץ הבתים (כלומר, האם בתים כגון 7 ו-12, שהיו קשים לחילוץ, הופכים לקלים ולהיפך עבור בתים אחרים). תוצאות מניסוי כזה יספקו הוכחה אמפירית לכך שקושי התקיפה הוא אכן ארטיפקט של המימוש התוכנתי ברמת המכונה, ועשויות להוביל לפיתוח שיטות קומפילציה מאובטחות יותר מפני התקפות ערוצי צד.

8. רשימת מקורות

[1] M. & Oswald, "Exploring Multi-Task Learning in the Context of Masked AES Implementations", *Springer*, 2024.

[2] P. & Rahimi, "Machine Learning-Based AES Key Recovery via Side-Channel Analysis on the ASCAD Dataset", *Springer*, 2025.

[3] B. & Invernizzi, "Generalized Power Attacks against Crypto", *CHES*, 2024.

[4] M. a. Oswald, 2024.

9. נספחים

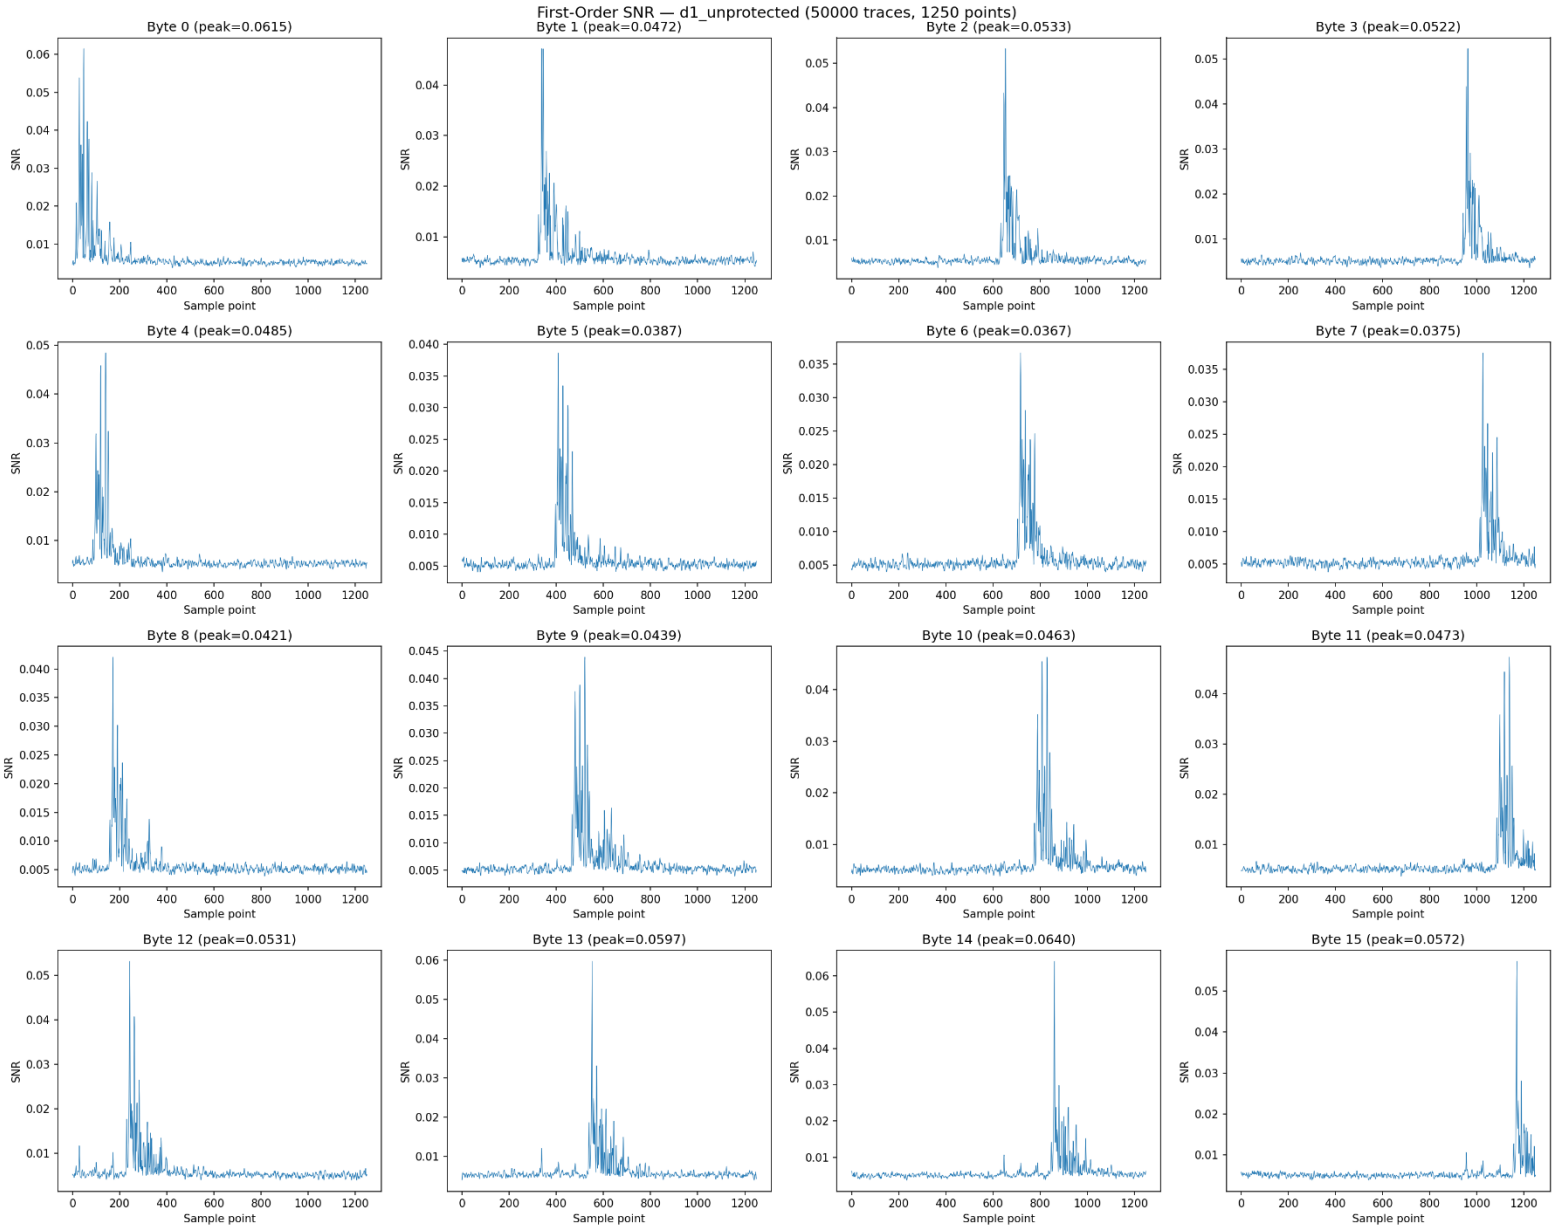

איור 10 - יחס אות לרעש מסדר ראשון על פני מצפין לא ממוסך

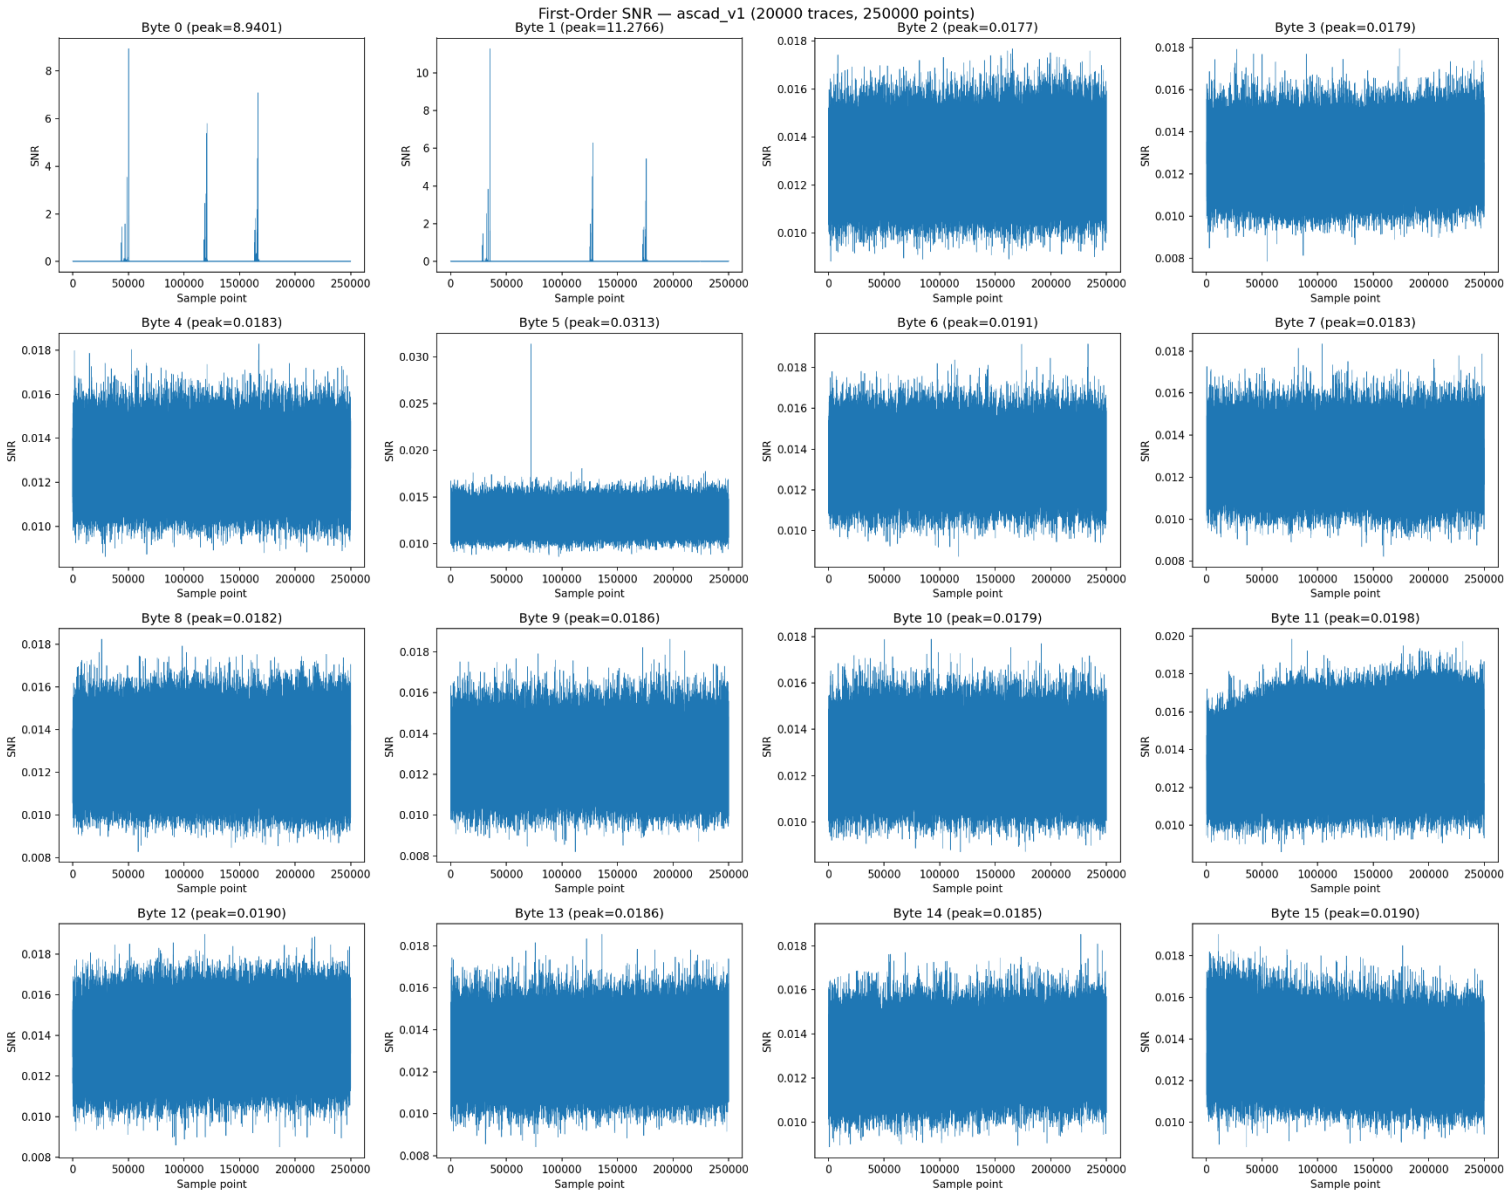

איור 11 – יחס אות לרעש מסדר ראשון ASCAD_r

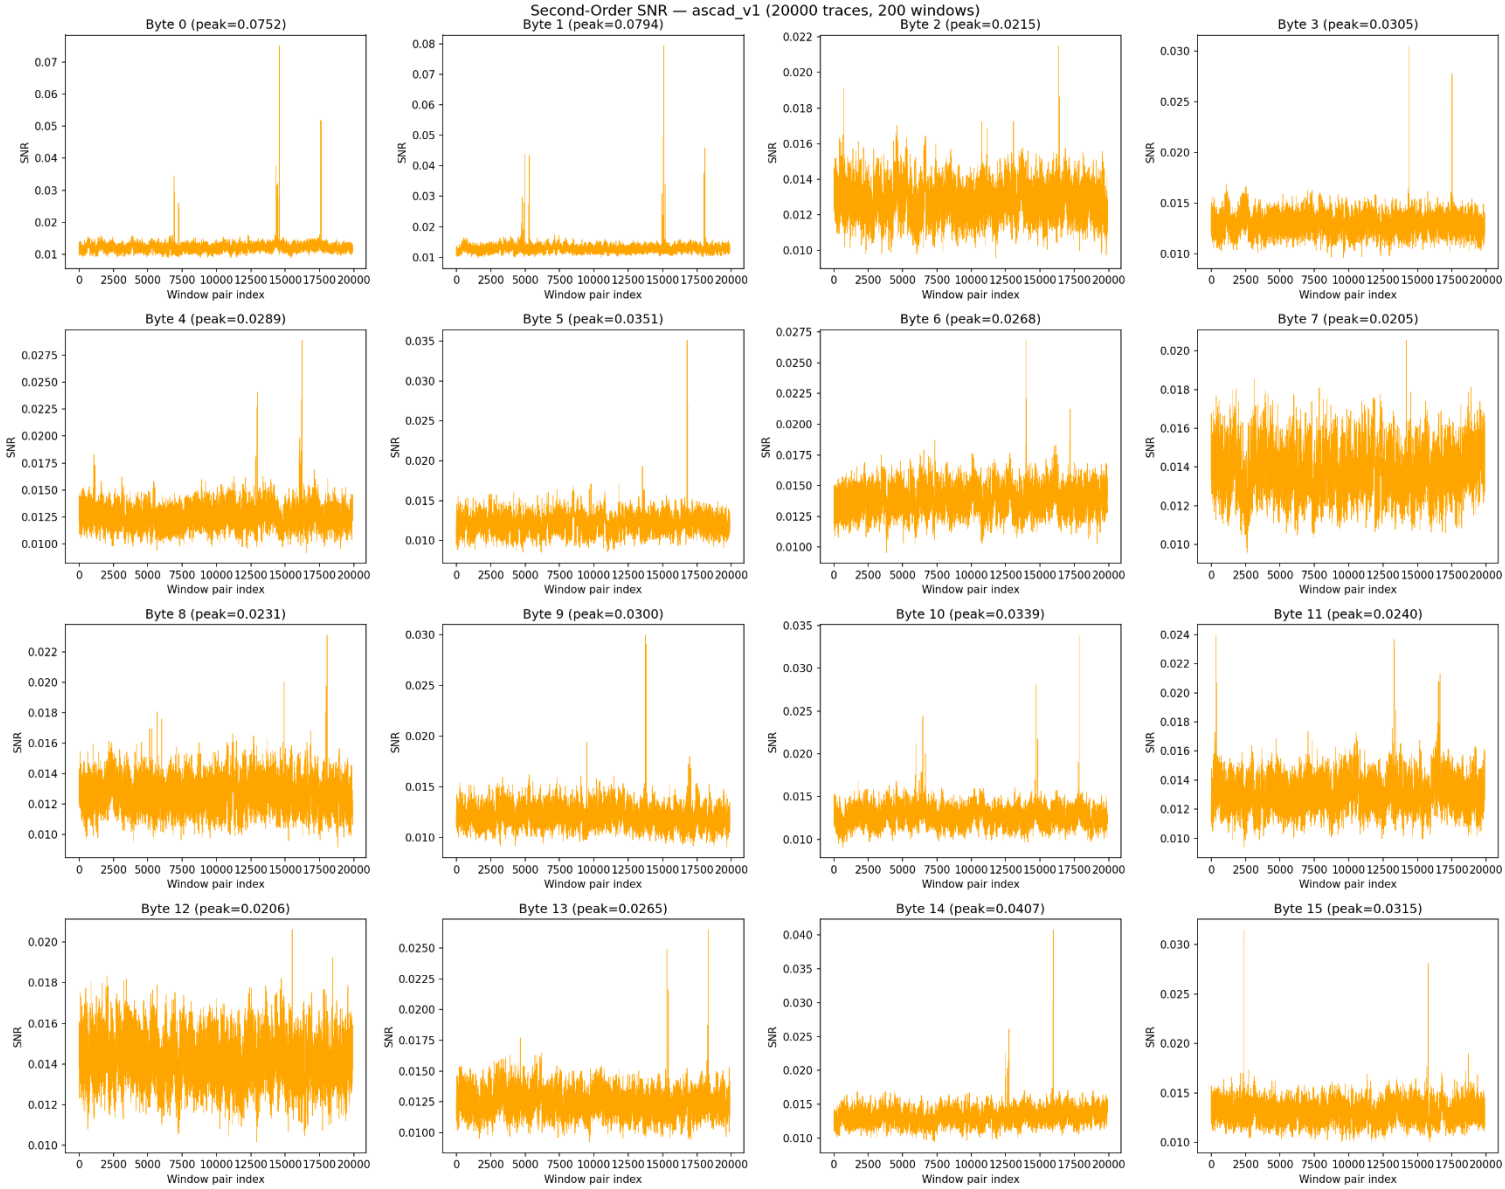

איור 12 – יחס אות לרעש מסדר שני ASCAD_r

=== Per-byte rank statistics (single-trace) ===

Byte	Mean	Median	Top-1%	Top-3%	Top-5%	Top-10%	Top-20%
2	2.3	1.0	54.6	85.4	93.6	98.4	99.7
3	5.0	3.0	31.7	59.6	73.9	89.2	96.4
4	1.8	1.0	60.8	90.4	96.9	99.6	100.0
5	1.8	1.0	60.6	91.0	97.2	99.8	100.0
6	1.9	1.0	59.4	89.6	96.2	99.4	99.9
7	3.1	2.0	44.2	76.6	87.5	96.2	99.1
8	3.2	2.0	43.3	74.4	86.5	95.7	99.1
9	1.6	1.0	67.2	94.4	98.8	99.9	100.0
10	3.2	2.0	47.5	77.3	87.5	95.1	98.2
11	1.7	1.0	66.0	92.8	97.6	99.7	100.0
12	3.9	2.0	39.9	69.8	82.2	92.8	97.9
13	3.5	2.0	39.8	70.7	83.0	94.1	99.0
14	1.7	1.0	66.2	93.6	98.0	99.7	100.0
15	2.6	2.0	48.3	79.0	89.8	97.6	99.8

איור 13 – ביצועי המודל הנבחר על פני עקבה בודדת: אחוז העקבות מתוך 10K עקבות עבורן דורג כל בית במקומות הראשונים בתקיפה

```
=== Cumulative log-probability attack ===

  Experiment 0:
    Trace   1: ranks=[1, 6, 4, 2, 1, 1, 1, 2, 1, 2, 12, 3, 1, 5] | mean=3.0 | max=12
    Trace   2: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 4, 1, 1, 1] | mean=1.2 | max=4
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1] | mean=1.1 | max=2
    Trace   4: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 4!

  Experiment 1:
    Trace   1: ranks=[5, 1, 2, 4, 3, 1, 1, 1, 6, 1, 4, 3, 1, 3] | mean=2.6 | max=6
    Trace   2: ranks=[2, 1, 2, 1, 1, 2, 1, 1, 2, 1, 2, 2, 1, 1] | mean=1.4 | max=2
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   4: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 4!

  Experiment 2:
    Trace   1: ranks=[1, 2, 1, 5, 1, 3, 1, 2, 1, 1, 17, 3, 1, 1] | mean=2.9 | max=17
    Trace   2: ranks=[1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 5, 1, 1, 1] | mean=1.4 | max=5
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 3!

  Experiment 3:
    Trace   1: ranks=[1, 9, 1, 1, 1, 2, 1, 1, 5, 3, 1, 1, 2, 1] | mean=2.1 | max=9
    Trace   2: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 2!

  Experiment 4:
    Trace   1: ranks=[2, 1, 1, 1, 2, 8, 1, 1, 1, 2, 4, 3, 1, 2] | mean=2.1 | max=8
    Trace   2: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 3, 1, 1] | mean=1.1 | max=3
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 3!
```

איור 14 – ביצועי המודל הנבחר על פני מספר עקבות: מספר העקבות המינימלי לחילוץ מלא של המפתח הסודי

=== Per-byte rank statistics (single-trace) ===

Byte	Mean	Median	Top-1%	Top-3%	Top-5%	Top-10%	Top-20%
2	6.0	3.0	27.5	54.7	68.7	85.2	94.4
3	6.3	3.0	25.1	50.6	64.8	82.5	94.3
4	5.1	3.0	29.5	58.0	72.6	88.1	96.3
5	4.8	3.0	30.1	59.5	73.9	89.5	97.0
6	7.2	4.0	24.9	49.4	63.2	80.5	92.2
7	7.9	4.0	21.8	46.0	59.7	77.7	91.1
8	5.7	3.0	29.0	55.9	69.6	85.8	95.3
9	6.0	3.0	25.4	52.2	67.0	84.0	94.8
10	5.4	3.0	30.8	57.8	71.7	87.2	95.7
11	6.0	3.0	27.5	54.4	68.6	84.7	94.5
12	6.3	3.0	25.7	51.2	65.6	83.6	94.7
13	5.3	3.0	29.6	56.4	70.5	86.1	96.3
14	6.1	3.0	27.0	53.2	67.0	83.7	94.5
15	4.3	2.0	35.3	63.6	77.3	90.5	97.6

איור15 - ביצועי מודל הבסיס על פני עקבה בודדת: אחוז העקבות מתוך 10K עקבות עבורן דורג כל בית במקומות הראשונים בתקיפה

```
=== Cumulative log-probability attack ===

  Experiment 0:
    Trace   1: ranks=[1, 1, 1, 1, 4, 1, 1, 3, 1, 1, 1, 1, 11, 1] | mean=2.1 | max=11
    Trace   2: ranks=[1, 1, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1, 3, 1] | mean=1.3 | max=3
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1] | mean=1.1 | max=2
    Trace   4: ranks=[1, 1, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   5: ranks=[1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   6: ranks=[1, 1, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   7: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 7!

  Experiment 1:
    Trace   1: ranks=[14, 4, 19, 2, 2, 1, 2, 9, 43, 1, 2, 3, 16, 5] | mean=8.8 | max=43
    Trace   2: ranks=[2, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 3, 2] | mean=1.4 | max=3
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 2, 2] | mean=1.2 | max=2
    Trace   4: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   5: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   6: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   7: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   8: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   9: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace  10: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace  11: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 2] | mean=1.1 | max=2
    Trace  12: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace  13: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace  14: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 14!

  Experiment 2:
    Trace   1: ranks=[1, 2, 1, 7, 1, 2, 2, 1, 1, 5, 1, 5, 7, 1] | mean=2.6 | max=7
    Trace   2: ranks=[1, 1, 2, 1, 1, 2, 1, 1, 1, 7, 1, 1, 1, 1] | mean=1.6 | max=7
    Trace   3: ranks=[1, 1, 2, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   4: ranks=[1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   5: ranks=[1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   6: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 6!

  Experiment 3:
    Trace   1: ranks=[11, 4, 5, 3, 1, 22, 1, 21, 5, 3, 3, 3, 1, 1] | mean=6.0 | max=22
    Trace   2: ranks=[5, 2, 2, 1, 1, 3, 1, 1, 2, 2, 1, 2, 1, 1] | mean=1.8 | max=5
    Trace   3: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 3!

  Experiment 4:
    Trace   1: ranks=[17, 34, 15, 11, 6, 22, 10, 6, 8, 4, 28, 5, 4, 5] | mean=12.5 | max=34
    Trace   2: ranks=[1, 3, 2, 3, 2, 4, 5, 1, 2, 4, 4, 1, 3, 1] | mean=2.6 | max=5
    Trace   3: ranks=[1, 4, 2, 3, 6, 9, 6, 1, 6, 3, 5, 4, 4, 1] | mean=3.9 | max=9
    Trace   4: ranks=[1, 1, 1, 2, 1, 7, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.5 | max=7
    Trace   5: ranks=[1, 1, 1, 1, 1, 5, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.3 | max=5
    Trace   6: ranks=[1, 1, 1, 1, 1, 2, 1, 1, 1, 2, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   7: ranks=[1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.1 | max=2
    Trace   8: ranks=[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1] | mean=1.0 | ALL TOP-1
    >>> ALL BYTES RECOVERED at trace 8!
```

איור 16 – ביצועי מודל הבסיס על פני מספר עקבות: מספר העקבות המינימלי לחילוץ מלא של המפתח הסודי